

分类号: TP391

密 级: 公开

单位代码: 10422

学 号: 202037499



山东大学
SHANDONG UNIVERSITY

硕士学位论文

Thesis for Master Degree
(专业学位)

论文题目: 基于协同过滤的个性化电影推荐系统

A Personalized Movie Recommendation System Based on
Collaborative Filtering

作者姓名 刘晓伟

培养单位 机电与信息工程学院

专业学位名称 通信工程

指导教师 殷建 教授

合作导师

2023 年 5 月 20 日

摘 要

近年来,互联网技术高速发展,为人们提供的服务日益增多,极大地丰富了人们的文娱生活,但是急剧增长的数据信息引起了信息过载问题。在信息过载的互联网时代,如何快速、有效地为用户提供有价值的信息,已经成为一个不可忽视的重要课题。与此同时,随着经济的发展,用户的需求也越来越个性化、多样化。在这种情况下,个性化推荐系统应运而生并得到了长足且快速的发展。协同过滤算法是推荐系统中应用最广泛且比较成功的一种方法,但它也有着不能忽视的缺点,比如说存在数据稀疏、冷启动、推荐效率低、耗时长等问题。因此,本文对协同过滤算法进行了深入的研究和改进,以提供更加优质的个性化推荐服务。本文首先展示了推荐系统中常用的几种算法,并着重介绍了它们的优缺点。然后,本文对传统协同过滤算法进行改进,提出两种新的算法,并使用改进后的推荐算法设计实现了个性化电影推荐系统。本文主要工作如下:

1.基于用户的协同过滤与基于物品的协同过滤的混合推荐算法。单一的推荐算法存在着劣势,比如说,基于用户的协同过滤存在用户冷启动、数据稀疏等问题,基于物品的协同过滤算法存在物品冷启动问题,且推荐的物品新颖性较差。为了解决单一推荐算法存在的问题并提升推荐质量,本文提出了混合推荐算法,主要工作包括:(1)使用修正后的余弦相似度计算公式去提升协同过滤算法中相似度的计算准确度。(2)对基于用户的协同过滤与基于物品的协同过滤算法进行加权融合,然后通过调整加权系数得到最佳推荐效果。实验证明本文提出的混合算法提升了系统推荐性能。

2.传统的协同过滤算法存在严重的数据稀疏问题以及用户相似度计算精度低的问题,本文对其改良,提出了一种基于用户聚类和改进用户相似度的协同过滤算法。针对数据稀疏问题,本文采用 K-means++ 聚类算法对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,从而获得稠密的用户-物品评分矩阵。然后,本文在更新后的矩阵基础上运行基于用户的协同过滤算法。在实现算法过程中,本文发现热门商品会影响用户相似度的计算,因而使用融合热门商品惩罚因子的皮尔逊相关系数来计算相似度。改进的算法不仅可以更准确地反映用户的行为,而且还可以更加有效地提升用户体验。

3.本文基于混合推荐算法开发了一套个性化电影推荐系统。首先分析讨论了该系统的可行性和功能需求;然后展示了系统总体架构以及系统的工作流程,并详细介绍了系统推荐服务流程;最后对系统功能进行实现和测试,测试结果表明,本系统运行稳定,可以为用户提供有效的个性化电影推荐服务。

关键词: 协同过滤; 混合推荐; K-means++ 聚类算法; 惩罚因子; 电影推荐系统

ABSTRACT

In recent years, the rapid development of Internet technology has provided people with an increasingly wide range of services, greatly enriching their cultural and recreational life, but the rapid growth of data and information has caused the problem of information overload. In the information explosion of the Internet era, how to provide valuable information to users quickly and effectively has become an important issue that cannot be ignored. At the same time, with the development of the economy, the needs of users are increasing and becoming more and more personalised and diverse. In this context, personalised recommendation system technology has emerged and is growing rapidly. The collaborative filtering algorithm is one of the most widely used and successful recommendation system technologies, but it also has some disadvantages that cannot be ignored, such as sparse data, cold start, low recommendation efficiency, and long time consuming. Therefore, this paper presents an in-depth study and improvement of the collaborative filtering algorithm in order to provide better personalised recommendation services. This paper first shows several of the most commonly used algorithms in recommendation systems and highlights their advantages and disadvantages. Then, this paper proposes a new recommendation algorithm based on the traditional collaborative filtering algorithm with improvements, and completes a personalised movie recommendation system based on the proposed algorithm, with the main work including:

1. A hybrid recommendation algorithm based on user-based collaborative filtering and item-based collaborative filtering. The single recommendation algorithm has disadvantages, for example, the user-based collaborative filtering suffers from user cold start and data sparsity, while the item-based collaborative filtering algorithm suffers from item cold start and the novelty of the recommended items is poor. In order to solve the problems of single recommendation algorithm and improve the quality of recommendation, this paper proposes a hybrid recommendation algorithm, the main work includes: (1) using the modified cosine similarity formula to improve the accuracy of similarity calculation in collaborative filtering algorithm; (2) weighting fusion of user-based collaborative filtering and item-based collaborative filtering algorithm, and then adjusting the weighting coefficient to get the best recommendation effect. Experiments demonstrate that the hybrid algorithm proposed in this paper improves the system recommendation performance.

2. The traditional collaborative filtering algorithm suffers from serious data sparsity

problem and low accuracy of user similarity calculation. This paper improves it and proposes a collaborative filtering algorithm based on user clustering and improved user similarity. To address the data sparsity problem, this paper adopts the K-means++ aggregation technique, using the K-means++ algorithm to cluster users and recreate the user-item rating matrix within each cluster, and finally using the reduced-scale matrix to implement the collaborative filtering algorithm; secondly, to address the problem that popular objects in the recommendation system affect the calculation of user similarity. Secondly, to address the problem that popular objects in the recommendation system can affect the accuracy of user similarity calculation, this paper introduces the penalty factor of popular products in the calculation of user similarity to reduce the influence of popular products, thus improving the recommendation performance of the algorithm.

3. This paper develops a personalized movie recommendation system based on the hybrid recommendation algorithm. Firstly, the feasibility and functional requirements of the system are analysed and discussed; secondly, the workflow of the system is elaborated from the overall architecture and database construction, and the recommendation service process is introduced in detail; finally, the system functions are implemented and tested, and the test results show that the system runs smoothly and can provide effective personalised movie recommendation services for users.

Key words: Collaborative filtering; hybrid algorithms; K-means++ clustering algorithms; penalty factors; movie recommendation systems

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 国外研究现状.....	3
1.2.2 国内研究现状.....	4
1.3 研究内容.....	5
1.4 组织结构.....	6
第 2 章 推荐系统及相关技术概述	7
2.1 个性化推荐技术.....	7
2.1.1 基于内容的推荐算法.....	7
2.1.2 协同过滤推荐算法.....	8
2.1.3 混合推荐算法.....	11
2.1.4 相似度计算方法.....	12
2.2 数据挖掘技术.....	13
2.3 系统开发技术.....	15
2.3.1 前端开发技术.....	15
2.3.2 后端开发技术.....	15
2.4 本章小结.....	16
第 3 章 基于用户和基于物品的混合模式推荐算法	17
3.1 混合模式推荐算法的介绍	17
3.1.1 混合模式推荐算法的重要性.....	17
3.1.2 混合模式推荐方法.....	17
3.2 混合模式推荐算法的工作流程	19
3.2.1 基于用户的协同过滤算法.....	19
3.2.2 基于物品的协同过滤算法.....	20
3.2.3 基于用户和基于物品的混合模式推荐设计思路	21
3.3 实验与结果分析.....	22
3.3.1 实验数据	22
3.3.2 实验方法	22
3.3.3 实验指标.....	23
3.3.4 实验结果分析.....	24
3.4 本章小结.....	26
第 4 章 基于用户聚类与改进用户相似度的协同过滤算法	27
4.1 基于 K-Means++算法的用户聚类	27

4.2 基于惩罚因子的用户相似度的改进	28
4.3 基于 K-means++算法与改进用户相似度的推荐算法设计思路	29
4.4 实验与结果分析.....	30
4.4.1 实验数据	30
4.4.2 实验指标	31
4.4.3 实验结果分析	31
4.5 本章小结.....	33
第 5 章 电影推荐系统的设计	34
5.1 系统分析.....	34
5.1.1 系统可行性分析.....	34
5.1.2 功能性需求分析.....	35
5.1.3 非功能性需求分析	38
5.2 系统设计.....	38
5.2.1 系统架构设计	38
5.2.2 系统推荐流程.....	39
5.2.3 数据库设计	40
5.3 系统功能的实现.....	41
5.3.1 注册与登录.....	41
5.3.2 管理员系统功能.....	43
5.3.3 普通用户功能.....	44
5.4 本章小结.....	47
第 6 章 总结与展望	48
参考文献.....	50

第 1 章 绪论

1.1 研究背景及意义

随着现代互联网信息技术、新一代人工智能和 5G 等先进科技的发展,人类正迈入一个全新的信息时代,大众的生活方式也发生了巨大改变。近日,中国互联网络信息中心(CNNIC)发表了第 51 次《中国互联网络发展状况统计报告》。根据最新报告,截至 2022 年 12 月,全国网友总量超过 10.67 亿,环比增加了 3549 万,网络平台科技应用率超过了 75.6%。可以说,网络技术已然融入了人们的日常生活,使得人们的日常变得更加便捷,比如说,购物能够使用移动支付,订购火车、飞机票能够通过网络购买,吃饭能够通过网络订购外卖或者线上订餐。然而凡事有利就有弊,以电子商务为例,购物平台为人们提供了优质的服务,便捷了人们生活的同时又带来了大量的就业机会^[1]。自 20 世纪以来,国内兴起了以阿里、京东、拼多多为代表的一众互联网企业,这些企业的出现,极大地改善了人们的生活质量。但是这些平台每天都会产生大量数据,而信息量的剧增又必然会导致“信息过载”现象^[2],同时也会对信息安全形成巨大挑战。

信息过载指的是在信息量急剧膨胀的互联网信息时代,信息过剩、信息价值降低等问题对人们的日常生活产生了负面影响^[3]。随着信息量的急剧增加,信息的质量急剧下降,从而导致人们无法准确分析和选择有效信息。在冗杂的网络信息中,人们筛选信息的效率十分低下,还常常找不到有效信息。

现实生活中人们会根据价格、时间紧迫性以及个人购物习惯去选择自己购买物品的方式。比如说,现在小李要去购买一本“推荐系统”书籍,那么他有三种购买方式。第一种,小李选择去学校的书店进行购买,因为书店里的书籍不多,询问店主后他就会把相关书籍递给小李。第二种,小李去市中心的新华书店购买书籍,因为新华书店书籍很多,小李需要先根据指示牌找到计算机类书籍,然后再根据“编程语言类书籍”指示牌找到他想要的书籍。第三种,小李会选择在淘宝、京东等购物平台来购买书籍,在平台上输入“推荐系统”关键字,系统会综合销量、价格、评价等指标给出推荐列表,小李也可以自己选择任一指标对商品进行排序购买。网购价格便宜、选择性多,但是时间上不占据优势,如果时间比较紧迫,小李还是会选择前两种购物方式。在上面的例子中,第一种方式由于书籍规模较小且店主很熟悉书籍的种类,因而能很快给出相关书籍。第二种和第三种方式就介绍了分类目录和搜索引擎是如何解决信息过载问题的。

近年来,科研人员和技术人员们不断努力,以克服网络信息过载的难题。他们提出了很多具有建设性意义的解决方案,当中最具特色的是分类目录和搜索引擎^[4],它们的应用范围最广,最受欢迎。随着技术的发展,网页的分类目录技术已经成为互联网的重要组成部分,它可以将网页按照一定的分类方式加以整理和分门别类,以便用户能够快

速找到所需的内容。雅虎、亚马逊等国际知名网站都采用了这一技术，而中国国内的Hao123也是一种分类目录站点，它能够覆盖大部分站点，但是一些小众或比较新颖的站点可能就不会被收录，这就使得用户在搜索过程中可能会遇到困难，从而无法获得自己想要的结果。同时，利用分类目录去寻找自己的需求信息时，需耗费大量时间和精力去层层筛选，这极大的影响了人们的工作效率，因而分类目录网站越来越不能满足人们的需求了。

为了解决分类目录技术存在的耗时长、效率低的问题，科研人员们提出了另一种解决方案，搜索引擎技术。用户通过搜索引擎输入关键词，继而搜索引擎利用关键字对互联网上的网页进行检索，并按照相关度从高到低的顺序对检索到的内容进行排序并展示给用户。谷歌利用搜索引擎技术成为世界闻名的互联网企业，国内的互联网公司也靠着搜索引擎技术在互联网领域站稳脚跟。搜索引擎能很好地解决人们“搜索难”的问题，但它也不能满足人们的所有需求。比如说，当人们想看电影但又想不到感兴趣的电影时，搜索引擎就无法为人们进行服务。在这种情况下，推荐系统技术应运而生，它能够根据用户行为历史为其提供优质的个性化推荐服务^[5]。

随着推荐系统的出现，人们可以更加便捷地搜索信息，它不仅可以主动将信息展示给使用者，而且还能够提升使用者的体验感。总的来说，互联网搜索引擎和推荐系统的目的是一致的，都是为了帮助使用者更有效地获取信息。与互联网搜索引擎有所不同，推荐系统可以依据使用者的行为历史数据构建兴趣模型，为使用者提供个性化的推荐服务，从而更好地满足用户的需求。一般情况下，如果用户有明确的需求，那么更适合使用搜索引擎来搜寻信息。推荐系统技术的诞生，不仅解决了推荐引擎的用户意图不明而导致的搜索结果不准确的问题，也提高了用户搜寻信息的效率^[6]，从而帮助用户快速寻找合乎自己兴趣爱好的信息。

2006年，美国《连线》期刊编辑克里斯发表了《长尾理论》，该书指出，20%的热门商品能够带来80%的销售额，而另外80%的冷门商品只能带来少量的收益^[7]。由于传统门店在销售商品时受到房租、人工等条件的制约，往往只能在货架上摆放最热门的商品，因而忽视了一些小众群体的需求，这降低了商家的收入的同时也打击了部分消费者的消费热情。但是随着互联网的发展，传统的8/2原则已经不复存在。推荐系统能够很好地挖掘长尾商品(long tail)，从而提升商品销售的效率。在互联网的电子商务中，由于上架商品的成本极低，因而店主往往可以在网站上销售很多商品，如果能选用高性能的推荐系统，商家能销售更多的长尾物品并从中获取不菲的利润。对于用户来说，推荐系统能够根据用户历史行为数据为其提供优质的推荐服务，从而帮助用户快速找到心仪的商品或信息。

个性化推荐系统能实现用户和商家的共赢，因而已经被广泛应用于电子商务之中^[8]，如购物网站：亚马逊、拼多多、阿里巴巴、京东商城等；视频网站：Youtube、腾讯视

频、乐视影视等；社交软件：Facebook、QQ、微信、微博等。大量的电商企业凭借着推荐系统技术收获了一大批用户，从而在互联网企业领域中站稳脚跟。

推荐系统的应用场景极其广阔，同时也有着很高的理论研究价值，这主要是因为使用个性化推荐系统不仅能为电商带来一批稳定的老用户，也能吸引来一大批新用户，自然能带来更好的营收。推荐系统的核心在于所采用的推荐算法，精心选择适合的算法可以实现用户和商家之间的双赢。协同过滤算法是推荐场景中应用最广泛且比较成功的一种算法，其运行成本低、推荐效果好，受到人们的广泛关注。但是，协同过滤算法也有着自身的劣势，比如说，算法存在着数据稀疏、冷启动、推荐效率低、耗时长等问题^[9]。本文在传统协同过滤算法的基础上进行改进，使其能够为用户提供更加优良的个性化推荐服务，并使用改进后的推荐算法设计实现了个性化电影推荐系统。

1.2 国内外研究现状

20 世纪末，国外的研究人员提出了“推荐系统”概念，时至今日，推荐系统已经发展成为一门单独的专业，其研究成果已被应用于社会、商品、文娱等众多应用领域，为人们提供了更多的选择^[10]。在社交领域，Facebook、Twitter 凭借着推荐技术获得不错的成果。在电子商务领域，亚马逊通过使用推荐系统一跃成为世界最大的电商平台，据调查，亚马逊“为你推荐”板块每年带来的收益要比“热门推荐”板块的收益多近一倍。在文娱领域，众多音乐、电影网站凭借出色的个性化推荐服务为其吸引来一大批用户。由于我国互联网起步较晚，早期的推荐系统研究大多是在国外进行的。近年来，随着互联网和机器学习的发展，我国对推荐系统的研究亦呈现出欣欣向荣的景象，大批科学家和工程师们提出了富有建设性意义的方案。

1.2.1 国外研究现状

由于国外互联网技术起步较早，在几十年前国外就已经开始对推荐系统进行研究，随着互联网和深度学习的发展，很多先进的技术如卷积神经网络、数据挖掘、强化学习技术被应用在推荐系统中，取得了优质的推荐效果。1992 年，科学家们提出了协同过滤推荐算法，该算法一经提出，就在科学界、工程界引起了广泛讨论。随后施乐公司的帕拉奥图研究中心在协同过滤算法基础上开发了一套垃圾邮件过滤系统^[11]，虽然该系统仍需要手工操作，但是这标志着人们研究推荐系统的开端。1994 年，美国明尼苏达大学的知名研究团队 Group Lens 研发了世界首套基于协同过滤的自动化推荐系统，该系统收集用户的历史行为数据，搜寻和目标用户兴趣相近的近邻集合，并利用近邻集合为目标用户提供推荐服务。后来，Group Lens 团队发表了 Movie Lens 数据集^[12]，该数据集深受学术界喜爱，至今已更新迭代了 6 个版本，是推荐系统中应用最多的数据集之一。1995 年 3 月，斯坦福学院的 Marko 教授在全美人工智能学会上发布了一款全新的推荐系统

LIRA, 而同年, 卡耐基梅隆学院的研究团队也发布了一款全新的个性化导航系统 Web Watcher^[13]。互联网公司雅虎在研究推荐系统的过程中发现了商机, 于 1996 年推出了雅虎的首个基于推荐系统的电商网站 My Yahoo, 这标志着推荐系统商业化的开始。随着互联网的发展, 推荐系统技术已经变得越来越成熟, 并已开始商业领域发挥重要作用。1998 年, Amazon 将协同过滤算法应用于电商网站^[14], 取得了丰厚的回报。据 Amazon 官方统计, 推荐系统使其营业额增长了 30%~40%。2000 年, NEC 研究院的 Kurt 等人在搜索引擎的基础上融合了推荐服务, 这为搜索引擎的发展打开了新篇章。2001 年, 推荐系统受到广大互联网公司的重视, 此后个性化推荐商业模式开始蓬勃发展。

2006 年, Netflix 大赛的举办将推荐算法的研究推向了前所未有的高度。为了提高推荐系统的准确性, 众多选手将新兴技术如卷积神经网络、数据挖掘、强化学习技术等应用于推荐系统, 为用户提供更加优质的推荐服务。至此, 各行各业都开始对其有所了解。文献[15]将信任关系因子融入了用户物品评分矩阵, 能够很好地消除数据缺失造成的影响。由于信任关系的特征维度较高且内容复杂, 因此需要将其转换为低维特征, 以便将其纳入用户物品评分矩阵中。由于时间因素对用户的兴趣偏好会产生影响, 文献[16]融合了用户的长期兴趣偏好特征和短期兴趣偏好特征, 为用户进行推荐。为了兼顾记忆能力和泛化能力, 谷歌应用商店推荐团队推出了 Wide&Deep 模型^[17]。该模型的 Wide 部分采用单输入层的简单模型, 因而记忆能力较强; 模型的 Deep 部分采用的是深度神经网络, 故而拥有强大的泛化能力。经测试, 使用了该模型的推荐系统具有优秀的推荐性能和较高的计算效率。对传统 GRU 架构进行扩展, 文献[18]提出了基于上下文注意力机制的 CARA 模型, 该模型能很好地利用上下文信息对用户签到顺序进行解释。文献[19]将 DNN 网络和 LSTM 网络相结合, 为用户提供推荐服务。该算法首先利用 DNN 深度神经网络对新的用户评分进行预测, 然后计算用户和物品之间的相似度, 最后使用 LSTM 长短期记忆网络进行推荐。M. Gupta 等提出了融合 KNN 的协同过滤算法^[20], 首先利用 KNN 算法将用户聚簇分类, 然后在分类基础上使用基于用户的协同过滤算法, 该算法消除了传统算法中相似度计算不准确的问题, 提高了系统的推荐性能。为了能够准确高效地获取用户特征以及物品特征, 文献[21]对传统的特征提取方法进行改进, 将有向信任等方法融合进了矩阵分解过程中。

1.2.2 国内研究现状

进入 21 世纪后, 中国的互联网产业蓬勃发展, 国内对推荐系统的研究和应用也提上了日程。通过合理应用互联网技术和推荐系统技术, 一大批优秀的互联网企业如阿里、腾讯、京东等在电商领域站稳脚跟, 其中最出名的事件当属阿里集团在中国市场上奇迹般击败世界 500 强跨境电商巨头 eBay。自此以后, 百度公司将推荐系统和搜索引擎共同作为公司的战略规划。从各个互联网企业的规划来看, 推荐系统仍是他们的战略目标

之一,我们也希望新技术的发展能将推荐系统推到一个新的高度。

推荐系统最重要的部分在于算法与模型。高质量的算法和模型能够有效地为客户提供个性化的推荐服务。文献[22]对现有的推荐算法和模型进行分析和总结,并针对不同问题和应用场景为人们推荐合适的算法或者模型。阿里巴巴 LS-PLM(大规模分段线性模型)应用于各类广告场景中,该算法首先对用户进行分簇聚类,然后在每一簇内进行逻辑回归预测[23]。传统的深度学习模型如 Embedding MLP, Wide&Deep 等都没有对特征交叉进行特别处理,仅仅是让独立的特征在网络里面进行自由组合,这样的特征交叉方法并不高效。为了解决这个问题,华为公司和哈尔滨工业大学联合提出深度学习模型 DeepFM^[24],该模型结构类似于 Wide&Deep 模型,由善于处理特征交叉的因子分解机 FM 模型和多层神经网络构成。为了高效地对高维特征进行特征交叉,上海交通大学的研究人员提出了 PNN 模型^[25]。该模型对 Deep Crossing 模型进行改进,使用乘积(Product Layer)替换了后者模型的 Stacking 层。PNN 模型通过 Product 方法对不同特征 Embedding 向量进行交互,从而有效地提取特征之间的关联信息。近年来,注意力机制的大火引起了国内推荐系统研究人员的注意。浙江大学的研究人员对 NFM 模型进行改进,提出了 AFM 模型^[26]。AFM 模型在 NFM 模型的输出层和特征交叉层之间加入了基于注意力机制的池化层,解决了 NFM 模型消解了大量有用信息的问题。阿里巴巴团队结合深度学习网络和注意力机制提出了 DIN 模型^[27]。该模型在用户兴趣建模过程中,使用注意力机制来聚合多个用户行为 Embedding 向量,让模型更加关注有用的信息,从而能够更好地捕捉用户的兴趣。DIN 模型使得阿里巴巴集团在电商场景中取得了较大的收益。

1.3 研究内容

推荐系统技术利用用户的历史行为数据为其推荐商品或者推送有效信息,能够有效地缓解信息过载问题。协同过滤算法成本低、推荐效果好,是现实应用最广泛且比较成功的一种算法,但是其在数据稀疏性、冷启动等方面表现不太好。为了解决这些问题,本文使用 K-means++算法对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,然后利用更新后的矩阵实现协同过滤算法。此外,本文还提出了一种混合加权推荐算法,并在其基础上实现了一套电影推荐系统。本文主要工作如下:

- 1.通过加权混合策略,对基于用户和物品的协同过滤算法进行混合,以提供更加精确的推荐结果。单一的推荐存在自己的劣势,利用混合推荐的方式能有效结合两种算法的优势,为用户提供更加优良的个性化推荐服务。

- 2.传统协同过滤算法的分析和改进。本文提出了一种新的协同过滤算法,它能够有效解决传统推荐中的数据稀疏问题。该方法采用 K-means++聚类算法,对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,最后利用更新后的矩阵来实现协同过滤算法。在实现算法过程中,本文发现热门商品会影响用户相似度的计算,因而使用融合热

门商品惩罚因子的皮尔逊相关系数来计算相似度。改进的算法不仅可以更准确地反映用户的行为，而且还可以更加有效地提升用户体验。

3.本文深入探讨电影推荐系统的功能要求和相关技术，并详尽阐述其架构、数据库的构建过程以及推荐服务流程。测试证明，该系统能够提供准确、可信的个性化推荐服务，从而满足用户的需要。

1.4 组织结构

本文总共分为六章：

第一章：绪论。本章深入探讨了推荐系统的研究背景和意义，然后对推荐系统的研究现状做出详尽剖析，最后确定文章的研究内容和组织结构。

第二章：推荐系统及相关技术概述。首先展示了三种应用较为广泛的推荐算法及其优缺点；然后介绍了数据挖掘技术以及常用的数据挖掘算法；最后从前后端角度对系统开发技术进行了阐述。

第三章：基于用户和基于物品的混合模式推荐算法。为了给用户提供更加优良的个性化推荐服务，本文提出了混合模式推荐算法。利用混合推荐的方式能有效结合两种算法的优势，主要工作包括：1.计算用户相似度时，本文使用修正后的余弦相似度计算公式，能为目标用户更加准确地找到近邻用户。2.对基于用户的协同过滤和基于物品的协同过滤算法进行加权融合，然后通过调整加权系数来得到最佳推荐结果。实验证明本文提出的混合算法提升了系统推荐性能。

第四章：基于用户聚类与改进用户相似度的协同过滤算法。针对数据稀疏问题，本文采用 K-means++ 聚类算法对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵，从而获得稠密的用户-物品评分矩阵。最后，本文在更新后的矩阵基础上运行基于用户的协同过滤算法。在实现算法的过程中，本文发现热门商品会影响用户相似度的计算准确度，为此我们在计算用户相似度时加入了热门商品的惩罚因子，这样能够帮助目标用户更加准确地找到近邻用户。

第五章：电影推荐系统的设计。本章从系统的可行性和用户需求出发，为用户展示了系统架构以及系统推荐服务流程。本系统使用了 Pycharm 平台以及 MySQL 数据库，采用前后端分离的方式进行开发。通过采用 Vue、HTML、CSS 和开源的组件库 Element UI 等前端技术，我们可以为用户提供个性化的推荐服务，让用户可以更加轻松地获取最佳的推荐结果。后端采用经典 MVC 框架(Python 的 Django 框架)进行开发，通过映射类与数据表的对象关系来对数据库进行操作。经测试，该系统运行稳定，能够很好地满足用户对电影的个性化需求，因此有一定的应用价值。

第六章：总结与展望。本章对研究工作加以深入的剖析和归纳，指出问题，并给出未来的方向，以期达到更好的研究成果。

第 2 章 推荐系统及相关技术概述

互联网技术推动人类进入信息时代，人们享受着互联网为他们带来的便利：吃饭可以在网上订餐或者点外卖，购物可以在电商平台上选择自己心仪的物品，甚至工作都可以居家远程办公，互联网融入了我们生活的方方面面。但是随着互联网的发展和普及，信息的数量呈指数倍增加，冗杂的信息让人们很难高效且准确地找到自己想要的信息。为了解决这个难题，科学家们提出过很多建设性解决方案，其中推荐系统是最受学界关注且行之有效的方案之一。随着互联网和深度学习的发展，很多先进的技术如数据挖掘、卷积神经网络、强化学习技术被应用在推荐系统中，取得了良好的效果。本文以个性化电影推荐系统为例，展示推荐系统搭建过程中用到的技术。

2.1 个性化推荐技术

个性化推荐技术利用用户历史行为和兴趣偏好等信息，为用户推荐符合其个性化需求的信息或产品。其核心思想是利用用户行为数据来构建用户画像，然后利用算法或者模型分析用户画像和商品画像之间的关系，从而为用户提供个性化推荐服务^[28]。本节为大家展示推荐系统中应用最广泛且比较成功的推荐技术。

2.1.1 基于内容的推荐算法

基于内容的推荐算法的核心思想是：根据用户的历史行为和兴趣爱好，分析出他们感兴趣的具体内容，并且能够依据这部分具体内容的特点和属性，计算出用户与待选商品相互之间的关联程度，从而为用户进行推荐^[29]。基于内容的推荐步骤大致分为三步，首先需要对商品进行特征提取并对提取的特征进行筛选和选择，将所选特征和特征权重组成一个特征向量，作为商品的物品画像。再根据用户历史行为和偏好进行分析和建模，得到用户画像。通过分析用户和商品的画像，我们可以计算出它们之间的相似度或匹配度，并以从高到低的顺序对商品进行排序，从而为用户提供最佳的 top-N 推荐。基于内容的推荐的原理如图 2-1 所示，这里有三位用户 X、Y、Z，三部电影 x、y、z，其中 x 是“喜剧、搞笑”类电影，y 是“战争、动作”类电影，z 是“喜剧、搞笑”类电影。目标用户 X 喜欢电影 x，用户 Y 喜欢电影 Y、用户 Z 喜欢电影 y、z。根据电影类型的分类，电影 x 和 z 都属于“喜剧、搞笑”类电影，既然目标用户 X 喜欢电影 x，那么用户 X 大概率也会喜欢电影 z，因而将电影 z 推荐给用户 X。




图 2-1 基于内容的推荐示意图

基于内容的推荐具有如下优点：

1 用户具有独立性：基于内容的推荐利用商品的画像和用户画像的匹配度来为目标用户进行推荐，并不考虑用户之间的关系。现实生活中，有些无良商家恶意竞争，给同行商家故意打低分，从而降低系统对该商家的推荐。此时，使用基于内容的推荐能很好地解决该问题。

2 能够解决系统冷启动问题。在一个新用户加入系统时，往往存在着系统冷启动问题，即系统无法准确地向目标用户推荐其感兴趣的物品。可以在用户注册时让用户选择他们感兴趣的标签，这样就能够利用基于内容的推荐为用户进行服务。

基于内容的推荐具有如下缺点：

1 基于内容的推荐的准确度受商品描述的准确性、特征提取的合理性、相似度计算精确度等因素的影响较大。如果不能很好地刻画用户画像和物品画像，那么推荐的效果自然会受到影响^[30]。

2 该算法推荐服务的新颖性较差。该算法推荐的物品和用户喜爱的物品十分相似，不具备多样性，因而难以发现用户的潜在兴趣。

2.1.2 协同过滤推荐算法

协同过滤算法是一种应用较多且性能较好的推荐算法，它能够依据用户的行为历史，分析用户、商品的关联性，从而找到相似的用户或商品^[31]。然后计算出目标用户对候选商品的评分，按照评分从高到低的顺序为用户进行推荐。

2.1.2.1 基于用户的协同过滤算法

利用基于用户的协同过滤算法，我们可以根据用户的行为数据，为他们提供最佳的推荐列表。该算法从用户近邻集合的物品库中筛选出与用户兴趣最相近的商品，并将其中的前 n 种商品作为最佳推荐，以满足用户的需求^[32]。简单来说，基于用户的协同过滤算法采用“人以群分”的思想。假如某人想要去看电影，那么他很可能会去询问他好友的意见，在得到不同好友的建议后他会综合选择一部合乎自己兴趣的电影，这一行为的本质是将有共同兴趣爱好的用户分成一类。该算法的步骤大致分为两步，首先计算用户相似度，以确定他们近邻集合。其次，对用户近邻集合的物品库中的商品做出评分预测，并依照打分从高到低的顺序，选出前 n 个商品，为用户进行推荐。算法的推荐原理如图 2-2 所示，假如这里有用户 X、Y、Z，电影 x、y、z、w。目标用户 X 喜欢电影 x、z，用户 Y 喜欢电影 y，用户 Z 喜欢电影 x、z、w。根据基于用户协同过滤的思想，目标用户 X、Z 都喜欢电影 x、z，这表明用户 X 和用户 Z 有相近的兴趣爱好，因而电影 w 可能也会受到用户 X 的喜爱。




图 2-2 基于用户的协同过滤示意图

基于用户的协同过滤算法的优点：

1 基于“人以群分”思想的协同过滤算法具有良好的可解释性，它能够从与目标用户兴趣爱好相似的近邻用户的商品集合中，精准地甄选出预测评分最高的 n 种商品，并将其提供给目标用户。因此，该算法具有较好的可解释性，即利用和目标用户兴趣相似的其他用户来推荐物品，能够让用户更加信任推荐结果^[33]。

2 该算法可以有效地筛选出与目标用户兴趣爱好最相似的近邻用户，并从用户近邻集合的物品库中挑选与用户兴趣最相近的商品，为用户进行推荐，所以推荐物品品类会很多，新颖性也较高。

3 推荐结果个性化程度高。该算法的推荐结果是利用和目标用户兴趣最相近的近邻用户来推荐生成的，因而大都符合目标用户的兴趣爱好。

基于用户的协同过滤算法的缺点：

1 数据稀疏问题。用户-商品评分在一个系统中是少之又少的，因此使用该类评分矩阵来计算用户相似度会带来不可预知的风险，从而影响推荐的准确性和可靠性。

2 当新用户进入系统时，由于缺乏任何行为数据，系统无法根据用户的历史行为来进行准确的推荐，这就是冷启动问题。该问题可以结合基于内容的推荐，或者使用聚类算法填充用户-物品评分矩阵来解决^[34]。

2.1.2.2 基于物品的协同过滤算法

基于物品的协同过滤算法可以从多种商品中找出与用户喜好商品最相似的商品，并将其推荐给用户。该算法利用商品之间的相似度，从而筛选出预测评分最高的前 n 种商品，以满足用户的需求^[35]。简单来说，基于用户的协同过滤算法采用“物以类聚”的思想。每个人都有自己独特的兴趣爱好，假如某人想要去看电影，那么他很可能会寻找一些和自己喜爱的电影类型相似的电影，并最终综合选择一个最想看的电影，这一行为的本质是将类型相似的物品分成一类。该算法的工作流程包括以下几个步骤：首先，计算物品的相似度，为目标物品选出类型最相近的近邻物品集合。其次，对这些物品进行评分预测，并根据评分从高到低的顺序选择前 n 个商品，最终推荐给目标用户。算法的推荐原理如图 2-3 所示，假如这里有用户 X、Y、Z，电影 x、y、z，其中 x 是“喜剧、搞笑”类电影，y 是“战争、动作”类电影，z 是“喜剧、搞笑”类电影。目标用户 X 喜欢电影 x、z，用户 Y 喜欢电影 x、y、z，用户 Z 喜欢电影 x。根据基于物品协同过滤的思想，电影 X、Z 类型相同，那么用户 Z 可能也会喜欢电影 X，因而将电影 X 推荐给用户 Z。




图 2-3 基于物品的协同过滤示意图

基于物品的协同过滤算法的优点：

1 该算法具有良好的可解释性：通过计算商品之间的相关性，可以找到与用户的近邻物品集合，并从中筛选出预测评分最高的前 n 种商品，以便为目标用户提供最优的推荐。因此，该算法具有出色的可解释性，它能够利用与目标用户喜好商品相似的近邻物品集合，从而让用户更加信任推荐结果。

2 缓解用户冷启动问题。用户冷启动问题是指推荐系统在处理新用户时遇到的问题，因为新用户没有足够的评分数据，导致无法根据用户的评分数据进行推荐^[36]。基于物品的协同过滤采用“物以类聚”的思想，通过对商品进行相似性计算，从而找到与新用户评分商品相近的其他商品，然后向新用户推送这些商品，从而缓解用户冷启动问题。

3 较低的计算复杂度。对于旧商品，系统已经计算过它们的相似度。当在新商品加入系统时，只需要计算其和所有旧商品的相似度即可，因而基于物品协同过滤算法的系统具有较低的计算复杂度。

基于物品的协同过滤算法同样存在缺点：推荐服务的新颖性较差。该算法能够利用商品的关联性来为目标客户提供推荐，以便更好地满足用户的兴趣喜好，但是这种方式也会导致推荐效果缺少创意性，不能深入挖掘客户的潜在趣味^[3]。

2.1.3 混合推荐算法

当使用单一的推荐算法进行推荐时，由于它们各自的优势和不足，很难给消费者带来完美的使用体验。因此，我们可以将这些算法融合在一起，以便充分发挥它们的优势。例如在 Youtube 网站中，其推荐引擎的设计分为两部分，首先利用影视类型给电影进行分类，并在分类后的电影集合中使用协同过滤算法得出推荐结果；然后将所有分类的推荐结果进行加权融合，为用户提供服务。理论上来说，算法中存在很多混合方式，但是最常见且行之有效的是流水线式、并行式以及整体式混合推荐^[37]。

(1) 流水线式

通过流水线式混合推荐，每一个算法的输出都可以被用于下一个算法，从而形成一个完整的推荐列表，以满足用户的需求。




图 2-4 流水线式混合推荐示意图

(2) 并行式

在并行式混合推荐中，每种算法都会得到一份推荐结果，对所有推荐结果进行加权混合，得到最终的推荐列表。




图 2-5 并行式混合推荐示意图

(3) 整体式

整体式混合推荐将众多算法融合在一起，从而为用户提供个性化服务，如图 2-6 所示。




图 2-6 整体式混合推荐示意图

2.1.4 相似度计算方法

本章讨论了几种常见的推荐算法，这几种算法的核心是相似度的计算。相似度用来衡量用户之间、物品之间或者用户和物品之间的相似程度，最常见的计算方式有杰卡德相似度(Jaccard Correlation)，余弦相似度(Cosine Correlation)以及皮尔逊相关系数(Pearson Correlation)^[38]。

(1) 杰卡德相似度(Jaccard Correlation)

杰卡德相似度是一个用来度量样品内部关联性和差异性的指标，它的值越大，表明样品之间的关联性越高，能够通过公式（2-1）来计算出来。

$$\text{Sim}(x, y) = \frac{|S_x \cap S_y|}{|S_x \cup S_y|} \quad (2-1)$$

其中 S_x 代表用户 x 喜爱的物品集合， S_y 代表用户 y 喜爱的物品集合，利用用户 x 、 y 喜爱物品交集的物品数量除以他们喜爱物品并集的物品数量，得到 Jaccard 相似系数的值。Jaccard 系数值接近 0，表示样本之间的相似度很低；Jaccard 系数值接近 1，表示样本之间相似度很高。

(2) 余弦相似度(Cosine Correlation)

余弦相似度(Cosine Correlation)是用来表示两个样本之间相关性的指标，它的计算方

式是通过测定二个矢量中间的夹角余弦值来确定。

$$\text{Sim}(x, y) = \cos(x, y) = \frac{x * x}{\|x\| * \|y\|} = \frac{|N(x) \cap N(y)|}{\sqrt{|N(x)| |N(y)|}} \quad (2-2)$$

其中 $N(x)$ 代表用户 x 有过评分记录的物品集合, $N(y)$ 代表用户 y 有过评分记录的物品集合。当余弦相似度接近 0 时, 表明样本之间的相关性较低, 而当余弦相似度接近 1 时, 则表明样本之间的相关性较高, 这与 Jaccard 系数的变化趋势相似。

(3) 皮尔逊相关系数(Pearson Correlation)

皮尔逊相关系数(Pearson Correlation)是一种度量样本相互之间线性关联程度的重要指标, 它可以用来反映样本内部的相关性, 取值范围在-1 到 1 之间, 计算公式如 2-3 所示。

$$\text{Sim}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (2-3)$$

用户 X 对第 i 个商品的评分是 X_i , $\bar{X}$ 代表了用户 X 对共同评过分的商品的评分均值; 而用户 Y 对第 i 个商品的评分是 Y_i , $\bar{Y}$ 代表了用户 Y 对共同评过分的商品的评分均值。皮尔逊相关系数的值越接近-1, 表示样本之间的线性相关程度越低, 皮尔逊相关系数的值越接近 1, 表示样本之间线性相关程度越高。

2.2 数据挖掘技术

数据挖掘是一种对海量信息进行分析和处理的方法, 它涵盖计算机系统科学和统计的多学科交叉方向, 旨在挖掘出有价值的信息和知识。通过计算机技术和统计学方法来探索数据中深层次的模式、联系, 并根据需求将数据以一种更容易理解的方式呈现在人们面前, 以便人们更好地应用数据。数据挖掘通常包括问题的定义、数据处理、建立数据挖掘模型、模型评估、结果应用等 5 个步骤^[39]。




图 2-7 数据挖掘技术示意图

问题的定义。在开始挖掘数据之前, 我们需要和问题相关领域的专家进行交流和沟通, 以了解问题的定义、背景知识和用户需求。深入了解问题的定义、背景知识有助于我们确定问题领域以及确定数据挖掘问题。同时, 想要充分发挥数据挖掘的作用, 我们必须深入了解用户需求, 即用户到底想要什么形式的结果。问题定义的结果在整个数据挖掘过程中起指导性作用。

数据处理。数据的处理工作可以分为以下几个部分：首先建立数据库，后续数据的采集和处理都将会在数据库中完成。然后是分析数据。我们需要对数据进行深入研究，探索数据中潜藏的模式、规律，调查相关对象彼此之间的联系。接下来是对数据进行调整。通过上面的步骤，我们对数据已经有足够的了解，接下来需要对这些数据进行调整，得到自己想要的数据格式，主要操作包括数据清理和数据转换。数据清理操作对数据中的缺失值、重复项、异常值进行处理。数据转换操作将数据从原始格式转换为可分析的格式，主要操作有数据聚合、数据离散化和数据变换等。

建立数据挖掘模型。在数据处理后，我们就能根据需求和应用场景来搭建数据挖掘模型了。该步骤是整个工作的核心部分，模型或者算法的优劣直接影响最终结果，最常用的方法有聚类、神经网络、决策树、异常检测等。利用数据挖掘技术我们能得到自己想要的信息或知识。

模型评估。尽管我们已经获得了一些模型，但它们并不总能满足人们的需求，有时候会出现偏差，甚至会出现与事实完全相反的结果，因此我们需要对模型加以评估。为了解决这个问题，我们常常会将数据集分为训练集和测试集，并利用训练集的信息来训练建模，以找到最优化的方法，并确定模型的结构，然后利用测试集来验证模型效果。模型评估常用的指标有预测误差和精确度等。根据评估指标对模型不断进行修正，以此达到最佳的效果。

结果应用。最后，将数据挖掘模型应用到现实场景中，为决策者提供有效信息。数据挖掘技术的应用场景极其广泛，可用于预测、个性化推荐和市场分析等领域。

在数据挖掘过程中，建立模型是至关重要的一步，其中最常用的算法包含关联分析、聚类分析和分类解析。关联分析可以帮助人们探索数据集中样本之间的相互依存关系，在日常生活中有着广泛的应用。比如说，利用关联算法对用户的购物习惯进行分析，发现用户购买 X 产品后，总会接着去买 Y 产品，人们可以改变货架布局，将 X 和 Y 商品一起销售，以此来提高销售额，这个思想最经典的案例莫过于“啤酒和尿布”。Apriori、FP-G 和 FreeSpan 是三种常用的关联算法，它们分别用于模式增长、模式投影和模式挖掘问题。分类算法利用某些特征或者属性对样品进行分类。分为一类的样品具有某些共同的特征，不一类的商品在这些特征或者属性上关联性较低。一些常见的分类算法，如朴素贝叶斯法(native Bayesian classifier)、k-最近邻法(KNN)、支持向量机(SVM)、决策树(神经网络)，都可以用来解决复杂的问题，并且具有良好的准确性和可靠性^[40]。聚类算法以相似性为基础，将相似度高的样本聚集成一类。和分类算法最大的不同点在于进行聚类操作时，系统仅仅按照相似度对样本进行聚类 and 划分，并没有预先设定类别，但是分类算法会预先设定好类别再进行分类工作。聚类算法是一种应用广泛的数据挖掘技术，其中最常见的有 K 均值聚合算法(K-means)、基于密度的聚类算法(DBSCAN)、凝聚层级聚类算法、图组织检测算法等。

2.3 系统开发技术

2.3.1 前端开发技术

Vue 框架是一种广受欢迎的前端 JavaScript 框架，它可以帮助用户创建出一个简洁、高效的界面。它由模板、组件、数据、方法和指令等组成^[41]，可以有效地提升用户体验，并且可以满足多种应用场景的需求。Vue 框架使用 HTML 模板来描述用户界面，开发人员可以使用 Vue 提供的指令来满足自己的页面开发需求。数据是前后端交互的关键，Vue 为用户提供了一个响应式的数据处理系统，可以通过简单的方法(api)实现数据绑定，使得用户界面随着数据的变化进行自动的更新。另外，我们可以通过使用 Vue 提供的指令对前端页面的布局、样式、图表等进行美化。

2.3.2 后端开发技术

(1) MVC 框架

为了进一步提高设计质量，本文采用了 MVC 框架(Model View Controller)作为程序架构设计方式。该构架将 AP 分割为 3 个部分：建模、视图和控件，以实现代码的分离^[42]。这种设计使得开发人员可以更加高效地开发、维护和测试应用程序，同时也使得应用程序更易于复用和扩展。MVC 框架如图 2-8 所示。




图 2-8 MVC 框架示意图

MVC 框架将系统的设计分为三部分：①视图(View)代表着用户交互页面，负责渲染前端页面以及数据的传输。视图通常会从控制器中获取数据，并使用前端 Vue 框架中的模板将数据渲染到前端页面中。控制器采集视图中的数据，并将数据输入到模型中，完成系统功能。②模型(Model)对应用程序的业务逻辑和数据处理工作进行管理。模型对视图传递的数据进行处理和存储，并将处理过的数据通过控制器重新传递给视图，从而对前端页面进行渲染。③控制器(Controller)。控制器是 MVC 框架中的一个重要的组成部分，它负责协调模型和视图之间的通信，对用户请求进行处理，从而完成应用程序的功

能。

(2) Django 框架

Django 是一种开放的 Web 架构，它采用 Python 语句设计，能够实现电影推荐系统的后端设计。该框架采用 MVC(Model-View-Controller)和 MTV(Model-Template-View)模式，以提高设计效率和质量^[43]。Django 框架为开发人员提供了许多工具和功能，使 Web 开发变得便利、快捷和安全，因而深受 Web 开发人员的喜爱。

2.4 本章小结

本章介绍了推荐系统的相关技术。首先展示了最常见的几种推荐算法，包括基于内容的推荐算法、基于用户的协同过滤算法、基于物品的协同过滤算法以及混合推荐算法，并对它们的优势和不足进行了深入的分析 and 比较。然后介绍了数据挖掘技术以及常用的数据挖掘算法。最后从系统前后端角度对系统开发技术进行了阐述。

第3章 基于用户和基于物品的混合模式推荐算法

3.1 混合模式推荐算法的介绍

3.1.1 混合模式推荐算法的重要性

在使用单一的推荐算法进行推荐时,每种方法都有各自的优点和缺点,因此无法为消费者提供最佳的使用体验^[44]。基于用户的协同过滤算法充分利用相似用户的评分,根据相似用户的反馈信息来预测评分,保证了推荐商品的新颖性。这种算法的应用范围比其他算法更加广泛,推荐结果的精确度也相对较高,但是也存在一些问题,比如数据稀疏问题和用户冷启动问题。另一种基于物品的协同过滤算法,它通过分析商品的特征和属性,找到与用户喜好商品相似的商品,并将其推荐给用户。该算法可解释性好,计算复杂度较低,而且能够在一定程度上解决新用户的冷启动问题。但是基于物品的协同过滤算法推荐商品的新颖性和物品多样性较低。

这样很自然地能想到,通过融合单一推荐算法,结合它们的优点来解决问题。当前的电子商务中,比如亚马逊、阿里巴巴、拼多多、网易等都不是采用单一的推荐算法,他们均采用融合多种算法的方式来改善单一算法的缺陷并提高推荐性能。

为了给用户提供更为精确的推荐结果,本文融合两种协同过滤算法,搭建出一个新的混合推荐模型,使两种算法互相搭配,解决了单一推荐方法中存在的冷启动、计算复杂度高和推荐创新性问题。

3.1.2 混合模式推荐方法

协同过滤算法是推荐系统技术中应用最广泛且比较成功的一种算法。基于用户的协同过滤算法经过对用户行为的研究,能够发现用户的偏爱和需求,从而为用户推荐与其兴趣爱好相匹配的商品。基于物品的协同过滤算法可以从多种商品中找到与用户喜好商品最相似的商品,并将其推荐给用户。两种方法相辅相成,基于用户的协同过滤可以在一定程度上缓解物品冷启动,并且其推荐的商品新颖性较高;而基于物品的协同过滤可以一定程度上解决前者存在的新用户冷启动问题。因此,利用合理的混合策略对两种协同过滤算法进行融合可以有效地解决推荐系统中的冷启动问题和推荐创新性问题,提高推荐的精确度和效率,具有很好的实际应用前景^[45]。

本文提出了一种新的混合方法,该方法采用并行式混合设计,将多种推荐算法的优势有机结合,从而实现了更加精准的推荐。混合模型策略如图 3-1 所示:




图 3-1 混合模型策略流程图

根据电影推荐的实际需求，对用户行为历史以及用户-电影数据集进行分析，决定使用加权混合策略。加权混合推荐系统使用不同的推荐算法来处理各种类型的用户数据和物品数据，该系统通过加权混合的方式将各个算法的推荐结果综合起来，形成最终的推荐列表，加权方法如下：

$$\hat{r}_{xi} = \sum_{k=1}^K w_k r_{xi}^{(k)} \quad (3-1)$$

其中， w_k 是第 k 个算法的预测权重， $\hat{r}_{xi}$ 是第 k 个算法对物品 i 的预测分数。确定加权混合推荐系统的权重有多种方法，例如使用 **stacking** 集成学习模型、根据验证集的性能表现、由用户确定权值等。在确定权重时，需要考虑到不同推荐算法的性能差异、用户偏好、数据分布特征等因素。在实际场景中，人们已经广泛应用加权混合式推荐系统，但该系统也存在着很多难题急需解决，比如说，如何选择适当的推荐算法和权重，如何平衡多个算法的推荐效果等等。

本文的混合策略选择的推荐算法是基于用户的协同过滤和基于物品的协同过滤算法，因而可将公式转化为

$$P = xP_{ucf} + yP_{icf} \quad (3-2)$$

公式中的系数 x, y 是可调的，需要实验过程中不断调试系数以达到最佳的推荐效果，其中 x 表示基于用户的协同过滤的电影评分预测权重， y 表示基于物品的协同过滤的电影评分预测权重。其中 x 和 y 需要满足： $x+y=1(0<x<1, 0<y<1)$ ，即二者的和为 1。讨论极端的情况：当 $x=1, y=0$ 时，混合系统可看作单一的基于用户的协同过滤推荐系统； $x=0, y=1$ 时，混合系统则可看作由单一的基于物品的协同过滤推荐系统。

通过加权混合两种算法，我们可以有效地处理冷启动的情况。两种算法相辅相成，基于物品的协同过滤算法在一定程度上能解决新用户冷启动问题，而基于用户的协同过

滤算法可以在一定程度上解决新物品冷启动问题，且推荐的物品新颖性较高。因此，利用合理的混合策略对两种协同过滤算法进行融合可以有效地改善推荐系统中的冷启动问题和推荐创新性问题，提高推荐的精确度和效率。

3.2 混合模式推荐算法的工作流程

3.2.1 基于用户的协同过滤算法

基于用户的协同过滤推荐算法采用“人以群分”的思想，它根据用户之间的相关性，找到用户的近邻用户^[46]，并从这些近邻用户的商品库中筛选出预期评价最高的 n 种商品，从而为目标用户提供最优的推荐列表。该算法通常包括 3 个步骤：收集用户行为数据、建立近邻用户集合以及产生推荐。

(1) 用户行为数据的收集

为了更好地推荐商品，我们需要收集用户的评分数据，并将其整理为表格，其中 m 代表用户总量， n 代表商品总量，表格中的 M_{mn} 代表用户 m 对商品 n 的评价。用户物品评分表如下所示。

表 3-1 用户物品-评分表

	item ₁	Item ₂		item _n
user ₁	M ₁₁	M ₁₂		M _{1n}
user ₂	M ₂₁	M ₂₂		M _{2n}
user ₃	M ₃₁	M ₃₂		M _{3n}
.....				
user _m	M _{m1}	M _{m2}		M _{mn}

(2) 近邻用户集合的建立

近邻用户集合是协同过滤算法中的一个重要概念，指的是与目标用户最为相似的一组用户集合。近邻用户集合的建立过程十分重要，其准确性和效率对于协同过滤算法的性能具有重要影响。

基于用户的协同过滤算法利用用户的相似性，从而找到近邻用户集合，并最终推送待选商品。如果选取不当的近邻用户集合，将会导致推荐结果不准确或者推荐效果不佳，从而影响用户的体验和满意度^[47]。其次，合理建立近邻用户集合可以提高推荐系统的工作效率。建立近邻用户集合是一项工作效率较低且耗时的任务，因此，采用合理的方式建立近邻用户集合，可以有效地减小工作量，从而提升系统的工作效率。

综上所述，近邻用户集合的建立协同过滤算法中具有重要的作用，合理地建立近邻用户集合不仅可以提高推荐系统的准确性，还可以提高推荐系统的效率。在协同过滤算法中，科研人员通过计算用户之间的相似度，来选取一组与目标用户兴趣爱好相似的用户，这组用户又被称为近邻用户集合。常用的相似度计算方法有余弦相似性公式，皮

尔逊相似度以及杰卡德距离公式等。本章使用修正余弦相似度来计算用户相似度，从而为用户寻找相似用户并建立近邻用户集合。

使用余弦相似度来计算用户评分相似度存在一定缺陷：在计算时没有考虑到用户的打分习惯和打分标准不一样。比如说，用户 X 对物品 1 和物品 2 评分为 4 分、5 分，用户 Y 对物品 1 和物品 2 评分为 1 分、2 分，利用余弦相似度公式计算两人的相似度，结果为 0.978。显然，这么高的相似度是不合逻辑的。使用修正余弦相似度可以有效地解决上述问题，在余弦相似度公式基础上，将每位用户对商品的评分减去用户评分的均值，以减小用户或物品的评分偏差对相似度计算的影响。计算公式如式(3-3)所示。

$$\text{Sim}(x, y) = \frac{\sum_{i \in I} (c_{xi} - \bar{c}_x) * (c_{yi} - \bar{c}_y)}{\sqrt{\sum_{i \in I} (c_{xi} - \bar{c}_x)^2} * \sqrt{\sum_{i \in I} (c_{yi} - \bar{c}_y)^2}} \quad (3-3)$$

用户 x 对第 i 个商品的评分是 c_{xi} ， $\bar{c}_x$ 代表了用户 x 对商品的平均评分；而用户 y 对第 i 个商品的评分是 c_{yi} ， $\bar{c}_y$ 代表了用户 y 对商品的平均评分。利用修正的余弦相似度来为用户寻找相似用户，在近邻用户的商品库中筛选出预期评价最高的 n 种商品，为目标用户进行推荐。

(3) 产生推荐

在确定目标用户的近邻用户集合之后，我们来预测集合中未被目标用户评过分的商品的表现。假设用户 x 的近邻用户集合为 NN_x ， $NN_x = \{NN_1, \dots, NN_n\}$ ，用户 x 对项目 i 的预测评分为 $P_{x,i}$ ，计算公式如下：

$$P_{x,i} = \tilde{R}_x + \frac{\sum_{y \in NN_x} \text{Sim}(x, y) * (R_{y,i} - \tilde{R}_y)}{\sum_{y \in NN_x} (|\text{Sim}(x, y)|)} \quad (3-4)$$

$\text{Sim}(x, y)$ 代表用户 x, y 之间的相似度，而 $R_{y,i}$ 则是用户 y 对商品 i 的评价， $\tilde{R}_y$ 表示的是用户 y 的评分均值， $\tilde{R}_x$ 表示的是用户 x 的评分均值。

我们将依照预测评分从高到低的方式对商品进行排序，并将前 N 种商品推荐给用户，以满足他们的需求。

3.2.2 基于物品的协同过滤算法

基于物品的协同过滤算法和基于用户的协同过滤算法所采用的思想十分相似，只不过前者是利用和用户喜好物品相似的物品来为用户进行推荐。通过基于物品的协同过滤算法，能够从商品库中找到与目标用户偏好商品类似的近邻商品集合^[48]，并从中筛选出预期评价最高的前 n 种商品，以此为用户提供推荐服务。这一过程包括三个步骤：收集用户行为数据、建立近邻物品集合以及产生推荐。

(1) 用户行为数据的收集

由于本文混合的两种算法采用的是一个数据集，故而实验过程中本小节直接使用 3.3.1 节建立的用户-物品评分表。

(2) 近邻商品集合的建立

对于目标用户喜爱的商品集合 $A\{A_1, A_2, \dots, A_n\}$ ，本文建立商品集合 A 的近邻商品集合，然后再从近邻商品集合中选出评分靠前的商品，将其汇总作为目标用户的推荐列表。本文利用商品之间的关联程度来确定商品的近邻商品集合，常用的计算方法有余弦相似度(Pearson Correlation)，皮尔逊(Pearson)相关系数以及杰卡德(Jaccard)相似度。本节使用修正余弦相似度来计算商品之间的相似度，从而为目标商品寻找相似商品并建立近邻商品集合。

$$\text{Sim}(i, j) = \frac{\sum_{x \in U_y} (c_{xi} - \bar{c}_i) * (c_{xj} - \bar{c}_j)}{\sqrt{\sum_{x \in U_y} (c_{xi} - \bar{c}_i)^2} * \sqrt{\sum_{x \in U_y} (c_{xj} - \bar{c}_j)^2}} \quad (3-5)$$

用户 x 对第 i 个商品的评分是 c_{xi} ， $\bar{c}_i$ 代表了商品 i 的平均评分；而用户 x 对第 j 个商品的评分是 c_{xj} ， $\bar{c}_j$ 代表了商品 j 的平均评分。

(3) 产生推荐

用户喜爱物品的近邻物品集合中的商品都将作为推荐给目标用户的候选商品，假设现在有候选商品 BI ，其物品近邻集合为 $LL_{BI} = \{LL_1, \dots, LL_k\}$ ，目标用户 a 对候选商品 BI 的预测评分为 $P_{a, BI}$ ，计算公式如下：

$$P_{a, BI} = \bar{R}_{BI} + \frac{\sum_{m \in LL_{BI}} \text{Sim}(BI, m) * (R_{a, m} - \bar{R}_m)}{\sum_{m \in LL_{BI}} (|\text{Sim}(BI, m)|)} \quad (3-6)$$

其中， $\bar{R}_{BI}$ 代表商品评分的平均值， $\text{Sim}(BI, m)$ 表示候选商品 BI 和其近邻商品 m 的相似度， $R_{a, m}$ 表示用户 a 对商品 m 的评分， $\bar{R}_m$ 表示商品 m 的评分均值。

我们将依照预测评分从高到低的方式对商品进行排序，并将前 N 种商品推荐给用户，以满足他们的需求。

3.2.3 基于用户和基于物品的混合模式推荐设计思路

本文的推荐策略是将基于用户的协同过滤推荐算法和基于物品的协同过滤算法进行加权融合，从而实现混合推荐。实验过程中需要不断调试参数，根据推荐效果来确定最佳的加权系数，最终给出最佳的推荐列表。

$$P = xP_{ucf} + yP_{icf} \quad (3-7)$$

公式中的系数 x, y 是可调的，需要实验过程中不断调试以达到最佳的推荐效果，其中 x 表示基于用户的协同过滤的电影评分预测权重， y 表示基于物品的协同过滤的电影

评分预测权重。这两个参数的取值会对物品的评分以及系统推荐性能产生重要影响。在混合推荐系统中，权重值的计算有很多，当中最常用的是专家经验法和实验法。专家经验法是一种基于科学家长期研究和实践的方法，它可以根据科学家的经验，提供各种可行的权重系数值。接下来实验人员需要进行实验来验证这些权重系数值的可行性。尽管该方法操作简易且方便，但是这种方法也会有不确定性，因为别人和自己的使用场景并不完全相同，故而不可盲目追求专家经验。本文拟使用实验法，根据推荐效果来确定最佳的加权系数。先给 x 设定 6 个值，分别为 0, 0.2, 0.4, 0.6, 0.8, 1，然后进行试验并观测不同系数下的推荐效果。根据推荐效果缩小 x 的取值范围并最终选择最佳的系数值。

3.3 实验与结果分析

3.3.1 实验数据

为了验证混合推荐算法的推荐效果，本试验采用 GroupLens 官网的 MovieLens 数据集进行实验，该数据集是推荐系统领域中最常用的数据集之一。MovieLens 数据集按照大小分别为 10M、1M 和 100k 三种数据集，为使用者提供了多种不同的选择。本文实验采用了 100K 的数据集，里面包括了 7808 位使用者、1682 部影片以及用户评价数据信息。这个数据集包括了一个文件，它记录了用户行为历史的所有信息，包括评分、评论、时间戳等。此外，数据集收集了详细的用户信息与电影信息，如用户的名称、性别、爱好、职业信息，电影的名称、类型、国家、主演信息等。用户的评分数据取值为整数且范围从 1 到 5。用户对电影感兴趣的程度随数值的增大而提高，其中 1 表示非常不感兴趣，5 表示非常感兴趣。

3.3.2 实验方法

推荐系统的实验方法有离线实验、在线实验、用户调查等。以上实验方法都有各自的优缺点和适用场景，实验时需要根据具体的问题和需求进行选择。

1 离线实验方法

离线实验(Offline Experiment)是推荐系统中常用的实验方法之一，它使用用户历史数据构建数据集，不需要用户过多地参与实验。离线实验的步骤：

- (1) 通过分析离线数据，收集用户的历史数据信息，并经过预处理，将其整合成一个标准数据集；
 - (2) 将整理好的数据集划分为训练集和测试集，常用的划分方法有留出法、交叉验证法、自助法等；
 - (3) 使用训练集来训练模型参数和确定模型结构，并利用测试集来验证模型效果。
 - (4) 选取合适的指标对测试集产生的推荐结果进行评估，以此衡量系统的推荐效果。
- 离线实验方法的优势在于其可以使用用户历史数据构建数据集，避免了对用户的干

扰,同时也降低了实验成本和风险。在离线情况下,实验人员也可以对算法进行快速迭代和优化,以提高推荐质量。缺点是离线实验无法考虑到推荐系统的动态性,如用户的兴趣演化、环境变化等因素,因此可能会导致推荐结果失真。

2 在线实验

在线实验(Online Experiment)是推荐系统中最常用的实验方法之一,它将推荐算法应用于在线环境中,利用真实用户的实时在线数据来评估算法的推荐性能。在线实验的优点如下:在线实验能够考虑到推荐系统的动态性和复杂性,可以实时反馈用户行为和环境变化,从而使得系统更准确地评估推荐系统的真实效果和性能。但是在线实验法实验成本较高,需要投入较多的人力和物力资源,而且还会涉及信息安全问题。

3 用户调查法

在推荐系统中,用户调查法通过向用户提供用户访谈或问卷调查等形式,来了解用户对推荐系统的使用感受。调查数据非常真实,能够充分反映用户的真实需求和反馈,因而用户调查法能够直接了解用户的感受和需求,可以更好地指导推荐系统的改进和优化。但用户调查法也存在自己的劣势:受到用户个体差异、职业因素甚至是环境因素等多种因素的影响,调查结果可能存在主观性和差异性。如果选择的调查对象不当,那么调查结果可信度也会降低。此外,调查过程需要耗费大量的人力和物力资源,而且还会涉及用户隐私和信息安全等重要问题。

3.3.3 实验指标

对于推荐算法,常用的评价指标为精确率和召回率,本实验也将采用这两种评价指标。

精确率(Precision)是指被推荐的物品中,用户实际感兴趣的物品的比例^[49]。在推荐系统中,精确率是关键评价指标之一,它用来度量系统推荐结果的准确性。精确率越高,推荐列表中用户实际感兴趣的物品数量也就越多。精确率的计算公式如下:

$$Precision = TP / (TP + FP) \quad (3-8)$$

其中, TP 表示被推荐的物品中用户实际感兴趣的物品数量, FP 表示被推荐的物品中用户不感兴趣的物品数量。

召回率(Recall)指的是系统推荐的用户感兴趣的物品数占用户喜欢物品数目的比例^[50]。召回率越高,表示系统能够找到用户实际喜欢的物品的比例越高,因此召回率也是推荐系统中一个非常重要的指标。召回率计算公式如下所示:

$$Precision = TP / (TP + FN) \quad (3-9)$$

其中, TP 表示被推荐的物品中用户实际感兴趣的物品数量, FN 表示用户实际感兴趣的物品中未被系统成功推荐的物品数量。

3.3.4 实验结果分析

本章选择采用离线实验的方式进行研究，将数据集依照 8:2 的比率划分为训练集和测试集。本文将使用训练集来训练用户兴趣模型，并通过优化参数来改善模型的结构，最后利用测试集来验证模型效果。

(1)与传统算法进行对比

为了证明混合推荐算法在推荐性能优于单一推荐算法，本文设计了一项实验。本文使用 Movie Lens-100k 数据集，观察混合推荐、基于用户和基于物品的协同过滤三种算法的精确率、召回率指标。为了在实验中获得准确的结果，实验者通过大量的调参工作，将权重系数 $x=0.7$ ， $y=0.3$ 。在实验验证分析中，把近邻用户数设定为 $N=15$ ，推荐电影的数量分别设定为 5、10、15、20、25、30，以此来评估三种算法的性能表现。




图 3-2 召回率对比图




图 3-3 精确率对比图

从图 3-2、3-3 可以看出，三种算法的召回率均与推荐电影的数量成正比，即召回率随着推荐电影数量的增加而提高，且本文提出的混合推荐模型的召回率要高于两种传统协同过滤算法的召回率。此外，三种算法精确率的变化与召回率正好相反，随着推荐电影数量的增加，三种算法的精确率均有所下降。三种算法的精确率与推荐电影的数量成反比，但混合推荐算法的精确率要高于其他两种传统算法。对比实验表明，本文提出的混合推荐算法有效提升了传统协同过滤算法的推荐性能。

(2)改进算法与其他算法的对比

进一步探索本文提出的混合推荐模型对比其他模型是否存在优势，本文设计了以下实验：将文献[51]提出的基于 k-means 用户聚类的混合协同过滤算法(记为 k-means-cf)、文献[52]提出的基于协同过滤的混合推荐(记为 collaborative filtering-cf)、文献[3]提出的基于协同过滤和基于内容的混合推荐(记为 collaborative filtering-content-cf)作为参考对象，观察本文提出的基于用户的协同过滤与基于物品的协同过滤的混合推荐算法(记为 user-item-cf)和三其他种算法的精确率、召回率指标。把近邻用户数设定为 $N=15$ ，推荐电影的数量分别设定为 5、10、15、20，以此来评估四种算法的性能表现。

表 3-2 改进算法与其他算法对比

	Items=5		Items=10		Items=15		Items=20	
	召回率	精确率	召回率	精确率	召回率	精确率	召回率	精确率
k-means-cf	0.037	0.286	0.075	0.252	0.102	0.226	0.117	0.194
collaborative filtering-cf	0.031	0.378	0.079	0.264	0.117	0.232	0.106	0.218
collaborative filtering-content-cf	0.059	0.318	0.069	0.297	0.105	0.241	0.112	0.209
user-item-cf	0.045	0.325	0.083	0.279	0.115	0.247	0.128	0.226

从表中可以看出，几种算法的召回率、精确率相差不大，但本文提出的混合协同过滤算法在召回率、精确率指标上整体要优于其他几种算法。在局部区域，Items=5 时，collaborative filtering-content-cf 的召回率高于本文的混合协同过滤算法，collaborative filtering-cf 的精确率高于本文的混合协同过滤算法，Items=10 时，collaborative filtering-content-cf 的精确率高于本文的混合协同过滤算法，但整体来说本文的混合协同过滤算法在推荐性能上要优于其他三种算法。单一的推荐存在自己的劣势，本文通过加权混合策略，对基于用户和物品的协同过滤算法进行混合，从而获得更加精确的推荐结果。

3.4 本章小结

在使用单一的推荐算法进行推荐时，每种方法都存在各自的优点和缺点，因此无法为消费者提供最佳的使用体验。本章通过使用加权融合的混合策略将两种协同过滤推荐算法的优势有机结合，从而解决了单一推荐方法中存在的冷启动和推荐创新性低等问题。为了验证这种混合策略的有效性，本文使用 MovieLens-100k 数据集进行了实验，结果表明，与单一算法相比，本文提出的混合推荐模型在推荐性能上有一定提升。

第 4 章 基于用户聚类与改进用户相似度的协同过滤算法

为了解决推荐系统中的数据稀疏问题,本文提出使用 K-means++算法对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,从而获得稠密的用户-物品评分矩阵,然后本文在更新后的矩阵基础上运行基于用户的协同过滤算法。此外,传统的相似度计算方法忽略了热门商品的影响,这将严重影响推荐结果的准确性,从而降低了用户体验。为了解决这些问题,本章将从以下两个角度对协同过滤算法进行改进:

(1) 使用聚类算法对用户进行分簇聚类,并在每一簇内重新建立用户-物品评分矩阵,这样能够很好地缓解数据稀疏性。

使用聚类算法来重新建立用户-物品评分矩阵可以很好地解决数据稀疏问题。经过调研,本文发现传统的 K-means 聚类算法存在着不足:随意选取初始聚类中心可能会造成局部最优解,进而影响聚类结果。为此,本课题提出使用 K-means++算法对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,该方法可以准确高效地对用户进行聚类,并且可以有效地降低数据的稀疏性。

(2) 本文在计算用户相似度时加入了热门商品的惩罚因子,这样能够帮助目标用户更加准确地找到近邻用户。

在传统的基于用户的协同过滤算法中,计算相似度仅仅使用了用户-项目评分数据,未曾考虑到热门商品的影响。在实现算法的过程中,本文发现热门商品会影响用户相似度的计算准确性,因而使用融合了热门商品惩罚因子的皮尔逊相关系数来计算相似度,这样能够帮助目标用户更加准确地找到近邻用户。

4.1 基于 K-Means++算法的用户聚类

在一个推荐系统中,用户-项目评分数据极其稀疏,这会导致推荐算法的效果不佳。通过 K-Means 聚类算法,能够有效地处理信息稀疏问题。利用该算法将用户集合划分成 K 个簇,并在每一簇内重新建立用户-物品评分矩阵,这样能够很好地缓解数据稀疏性。然而,经过深入研究,发现该算法具有一定的不足之处:随意选取初始聚类中心,可能会出现局部最优状况,进而影响结果的准确性^[53]。我们采用 K-Means++方法将用户聚成簇并在每一簇内重新建立用户-物品评分矩阵,有效地解决了传统 K-Means 方法中存在的聚合结果不准确的问题,大大提高了聚类的准确度,同时也降低了数据的稀疏性。

相较于 K-means 算法, K-means++算法能够有效地选择初始聚类中心,并且将它们之间的距离尽可能地拉远。这种算法比传统的 K-means++算法更加精确,能够更好地捕捉数据集中的特征。K-means++算法具有出色的操作性能,且效率和可靠性较高,能够有效地处理大规模数据^[54]。下表为 K-means++聚类算法的详细步骤:

表 4-1 K-means++聚类算法详细步骤

输入：初始数据集 X 由 $\{x_1, x_2, \dots, x_n\}$ 组成，聚类数量为 K 。
输出：满足准则函数和误差平方函数收敛的 K 个簇。
1 随机从数据集中选取一个对象作为初始聚类中心 A_1 。
2 计算每个点到当前聚类中心点之间的最小欧氏距离，以 $B(x)$ 的形式表示，以便更好地捕捉聚类中心点的特征。
3 根据 $B(x)$ 值的大小，选择更有可能成为聚类中心的点，以此来提高聚类的准确性和可靠性。
(1) 将当前每个聚类中心点的聚类对象的 $B(x)$ 进行累加，其和为 $\text{sum}(B(x))$;
(2) 取一个随机值 Rad ($0 \leq Rad \leq \text{sum}(B(x))$)，令 $Rad = Rad - B(x)$ ，直到 $Rad \leq 0$ ，此时的点就是新的聚类中心。
4 循环执行第 2 步和第 3 步，直至选出 K 个聚类中心 $\{a_1, a_2, \dots, a_k\}$ 。
5 计算每个点 x_i 到 K 个聚类中心之间的欧几里得距离，并将其划分到最近的簇中。
6 在每个簇 a_i 中更新聚类中心： $a_i = \frac{1}{ a_i } \sum_{x \in a_i} x$
7 对第五和第六步进行循环迭代计算，直到准则函数和误差平方收敛。

利用得到的聚类中心将用户集合划分成 K 个簇，使得簇内用户的兴趣爱好尽可能相近，并在每一簇内重新建立用户-物品评分矩阵，最后，本文在缩小规模的矩阵基础上运行基于用户的协同过滤算法。通过 K-means++ 算法对传统协同过滤算法进行改进，不仅在一定程度上解决了评分矩阵的稀疏性，同时也提高了推荐的效率和准确率。

4.2 基于惩罚因子的用户相似度的改进

在电商平台上，热门榜单往往会被推荐给每一位用户，但是它们并不能真实反映用户的兴趣爱好。假设现在有两位用户观看了影片 1 和影片 2，而且他们对两部影片的评价非常接近。影片 1 受到了广大观众的喜爱，大多数用户都看过影片 1，并且评价也非常接近，但这并不能说明两位用户的兴趣爱好相近，因为这部影片的热门程度使得它得到了大多数消费者的认可，这也是多数消费者的共同特征。相反，如果影片 2 是一部冷门影片，那么它的观看次数就会相对较少。当两位用户对影片 2 的评价相近时，他们双方的相似度就会更高，这是因为冷门商品更能够捕捉到用户的偏好，而热门商品则无法捕捉到这种偏好^[55]。

热点商品通常是大多数用户都喜欢或购买过的商品，因此，冷门商品更能反映出两个用户之间的兴趣相似性^[56]。例如，两个消费者都购买了字典，但这并不能证明他们的兴趣相近，因为字典是一种常见的方法书，在学习中也会有所应用。假如两位客户都购买了《通信原理》，就能推断他们有着相近的偏好，因为通常大多数情况下只有通信工

程专业的学生会用到这本书。为了更准确地评估客户的相似程度,本章提供了一种新的方法,即在计算用户相似度时加入一种惩罚因子,以抑制热门商品对推荐结果的负面影响。惩罚项定义如式(4-1)所示。

$$\frac{1}{\lg(1+|N(i)|)} \quad (4-1)$$

将式(4-1)融入皮尔逊系数,得到修正相似度计算方法,如式(4-2)。

$$\text{Sim}(X,Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) \frac{1}{\lg(1+|N(i)|)}}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (4-2)$$

用户 X 对第 i 个商品的评分是 X_i , $\bar{X}$ 代表了用户 X 对共同评过分的商品的评分均值;而用户 Y 对第 i 个商品的评分是 Y_i , $\bar{Y}$ 代表了用户 Y 对共同评过分的商品的评分均值。

4.3 基于 K-means++ 算法与改进用户相似度的推荐算法设计思路

通过 4.1 节中的 K-means++ 聚类算法,对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,从而获得稠密的用户-物品评分矩阵,然后本文在更新后的矩阵中运行基于用户的协同过滤算法。在实现算法过程中,本文导入了热门商品的惩罚因子,并对用户相似度计算公式做出了修正。最终,我们利用评分公式对未评价的商品做出了评分预测。假设用户 x 的邻用户集合为 NN_x , $NN_x = \{NN_1, \dots, NN_n\}$, 用户 x 对项目 i 的预测评分为 $P_{x,i}$, 计算公式如下:

$$P_{x,i} = \tilde{R}_x + \frac{\sum_{y \in NN_x} \text{Sim}(x,y) * (R_{y,i} - \tilde{R}_y)}{\sum_{y \in NN_x} (|\text{Sim}(x,y)|)} \quad (4-3)$$

$\text{Sim}(x,y)$ 代表的是用户 x,y 之间的相似度, $R_{y,i}$ 代表用户 y 对商品 i 的评价, $\tilde{R}_y$ 代表用户 y 的评分均值, $\tilde{R}_x$ 代表用户 x 的评分均值。本文将按照预测评分从高到低的次序对商品加以排名,并将评分靠前的 N 种商品推荐给用户。

该算法的流程如下所示:

表 4-2 改进的协同过滤算法的详细步骤

输入：用户 x ，用户物品评分矩阵
输出：用户 x 的推荐列表
1 使用 K-means++ 聚类算法，获得用户 x 所在的簇 S ，并在 S 簇内重新建立用户-物品评分矩阵 C 。
2 在 C 中，利用公式(4-1)计算每个商品的惩罚因子系数。
3 在 C 中，利用加入惩罚因子的相似度计算公式(4-2)计算用户 x 和所有用户的相似度。
4 将相似度靠前的 m 个用户选为 x 的近邻用户。
5 利用 x 的近邻用户，通过公式(4-3)计算用户 x 对商品的评分。
按照预测评分从高到低的次序对商品加以排名，并将评分靠前的 N 种商品推荐给用户。

该算法的流程图如图 4-1 所示：




图 4-1 改进的协同过滤算法流程图

4.4 实验与结果分析

4.4.1 实验数据

本章实验使用 Movie Lens-100 数据集，以检验基于 K-means++ 算法和惩罚因子的协同过滤算法是否能够更有效地推荐商品。结合实验场景，本章使用离线实验法进行测试。本文将数据集依照 8:2 的比率分类为训练集和测试集，使用训练集来训练用户兴趣模型，并通过优化参数来改善模型的结构，最后利用测试集来验证模型效果。

4.4.2 实验指标

本节使用精确率和召回率评价指标来检验算法的推荐性能。精确率(Precision)是指被推荐的物品中,用户实际感兴趣的物品的比例^[50];召回率(Recall)指的是系统推荐的用户感兴趣的物品数占用户喜欢物品数目的比例^[51]。具体计算公式见公式 3-8、3-9。

4.4.3 实验结果分析

(1) 与传统算法进行对比

根据 4.3 节所述,使用 K-means++算法对用户进行聚类并在每一簇内重新建立用户-物品评分矩阵,从而获得稠密的用户-物品评分矩阵。在更新后的矩阵中,根据 4.2 节引入热门商品的惩罚因子,对用户相似度计算公式进行改进,最后根据协同过滤算法思想对用户未评分的商品进行评分预测及推荐。为了证明本文提出的方法比传统协同过滤算法更有效地提升推荐质量,本文设计了以下试验,使用 Movie Lens-100k 数据集,观察基于 K-means++算法与改进用户相似度的协同过滤算法和传统基于用户的协同过滤算法的精确率、召回率指标。为了在实验中获得准确的结果,实验者通过大量的调参工作,将初始聚类中心参数设置为 $k=5$ 。在实验验证分析中,把近邻用户数设定为 $N=15$,推荐电影的数量分别设定为 5、10、15、20、25、30,以此来评估两算法的性能表现。




图 4-2 召回率对比图




图 4-3 精确率对比图

图 4-2 和图 4-3 为两种算法的召回率、精确率对比图。实验结果表明，两种算法的召回率均与推荐电影的数量成正比，即召回率随着推荐电影数量的增加而提高。而两种算法精确率的变化与召回率正好相反，随着推荐电影数量的增加，两种算法的精确率均有所下降。但是本文提出的改进算法的折线图在两种指标下都高于传统算法，因而得出结论，本文提出的改进算法有效提升了传统协同过滤算法的推荐效果。

(2)改进算法与其他算法的对比

进一步探索本文提出的混合推荐模型对比其他模型是否存在优势，本文设计了以下实验：将文献[57]中的基于 k-means 用户聚类的混合协同过滤算法(简称 k-means-cf)、文献[58]中的基于户行为时间差和视频流行度的协同过滤算法(简称 TP-User-CF)以及基于显隐式反馈评分的用户协同过滤推荐算法(简称 TP-EI-Use-CF)作为参考对象，观察本文提出的基于用户聚类与改进用户相似度的协同过滤算法(记为 K-means++-cf)和三其他种算法的精确率、召回率指标。把近邻用户数设定为 N=15，推荐电影的数量分别设定为 5、10、15、20，以此来评估四种算法的性能表现。

表 4-2 改进算法与其他算法对比

	Items=5		Items=10		Items=15		Items=20	
	召回率	精确率	召回率	精确率	召回率	精确率	召回率	精确率
kmeans-cf	0.038	0.296	0.067	0.247	0.089	0.217	0.116	0.191
TP-User-CF	0.031	0.285	0.083	0.249	0.088	0.246	0.109	0.188
TP-EI-Use-CF	0.037	0.309	0.071	0.278	0.095	0.246	0.117	0.202
k-means++-cf	0.040	0.315	0.072	0.260	0.100	0.223	0.120	0.208

从表中可以看出，几种算法的召回率、精确率相差不大，但本文提出的基于用户聚类与改进用户相似度的协同过滤算法在召回率、精确率指标上整体要优于其他几种算法。在局部区域，Items=10 时，TP-User-CF 的召回率高于本文的混合协同过滤算法，TP-EI-Use-CF 的精确率高于本文的混合协同过滤算法，Items=15 时，TP-EI-Use-CF 的精确率高于本文的混合协同过滤算法，但整体来说本文的基于用户聚类与改进用户相似度的协同过滤算法在推荐性能上要优于其他三种算法，因而本文提出的聚类、惩罚因子等技术有较高的应用价值。

4.5 本章小结

本章通过使用聚类算法重新建立用户-物品评分矩阵，加入惩罚因子等方式来解决传统协同过滤算法中存在的 数据稀疏，用户相似度计算不准确等问题。根据提出的算法思想，从用户聚类、惩罚热门商品两个方面对传统算法进行改良，提出了基于 K-means++ 算法与改进用户相似度的协同过滤算法。利用 MovieLens-100k 数据集进行实验与分析，结果表明，相较于传统协同过滤算法，本章提出的改进算法在推荐性能方面有了一定的提升。

第 5 章 电影推荐系统的设计

5.1 系统分析

基于第三章的加权混合推荐系统,本文设计开发了一套电影推荐系统,它可以依据用户的观影记录和评价,为用户提供电影推荐服务。该系统不仅可以为用户提供最新最热门的电影推荐,还可以按照用户的喜好为其提供个性化的服务。该系统采取了前后端分离的方式进行开发,前端应用了 Vue.js 架构,后端则应用了经典的 MVC 架构和 Python 的 Django 架构。本系统使用的数据库是 MySQL,通过映射类与数据表的对象关系来对数据库进行操作^[57]。系统开发环境如下。

表 5-1 系统开发环境

名称	具体配置信息
开发软件	Pycharm
操作系统	Windows
开发语言	Python/HTML/CSS
数据库	MySQL

为了更好地实现基于混合策略的电影推荐系统,在系统设计之前,对系统进行分析。首先从技术、操作、经济等方面进行可行性分析,然后再对系统进行功能性和非功能性分析。

5.1.1 系统可行性分析

(1) 技术可行性

本系统使用了 Pycharm 平台以及 MySQL 数据库,采用前后端分离的方式进行开发。前端使用了多种高新技术,包括 Vue、HTML、CSS 和开放的组件库 Element UI,以此来向用户展示推荐结果,为用户提供个性化的推荐服务。后端采用经典 MVC 框架(Python 的 Django 框架)进行开发,通过映射类与数据表的对象关系来对数据库进行操作。综上所述,该系统的技术可行性是很充分的。

(2) 操作可行性

本电影推荐系统页面可视化强,操作简单,易于上手,用户会上网即可使用本系统。用户通过简单的注册登陆,在对电影评分后,系统就能根据用户的评分数据分析用户的兴趣喜好并为用户推送视频。所以,本系统在操作上也是可行的。

(3) 经济可行性

由于系统开发技术比较成熟,并且硬件设备要求不高,因而整体开发成本较低。学校为每一位研究生配备了专用电脑,其性能能够满足系统开发的需求。通过使用 Pycharm 专业版软件,我们可以申请该软件为高校学生和教师提供免费的开发计划,每次申请可

以获得一年的时间，足以满足开发需求。因此，这个系统在经济上是可行的。

5.1.2 功能性需求分析

为了给用户提供高质量的个性化电影推荐服务，本文利用混合推荐模型开发了一套电影推荐系统。电影推荐系统的用户主要是观看电影的普通用户和系统管理员，用户不同，系统提供的功能也不相同。对于普通用户，系统需要提供普通用户功能、数据采集、数据预处理和推荐引擎等功能。管理员负责电影推荐系统的运行和维护^[58]，因而系统会为管理员提供各种系统管理功能。系统功能架构图如图 5-1 所示。




图 5-1 系统功能架构图

(1) 普通用户功能

电影推荐系统旨在为用户提供便捷的影视信息查询服务，未注册用户可以轻松获取最新的热门影片排行榜，但是想要获得个性化的推荐，则需要先完成注册和登录。用户注册后，只需输入正确的用户名和密码，系统就会提供相应的功能。当用户的注册或登录步骤出错时，系统会自行提示用户。用户登录系统后，可以查看个性化的推荐列表，并可以按照自己的兴趣爱好对影片予以评分和评论，评分的范围为 1-5 分，分数越高说明用户对该影片越感兴趣。此外，本系统还为用户提供了意见反馈功能，当用户遇到问题或困难时，可以立马反馈问题，管理者能够根据用户的反馈解决问题或者对系统进行改进，从而提供更好的服务。普通用户功能如图 5-2 所示。




图 5-2 普通用户功能示意图

(2) 数据采集功能

当用户与系统交互时，数据采集模块会在网页前端进行埋点，以收集用户的行为历史数据，包含浏览记录、评分等。此外，它还负责管理和收集电影信息和系统日志，以便更好地为用户进行推荐。该模块如下所示。




图 5-3 数据采集功能示意图

(3) 数据预处理功能

数据预处理模块负责处理系统收集的数据，通过数据清洗、数据分类与合并、数据存储等操作，该模块可以有效地对数据进行处理。系统处理后的数据将被用于混合推荐模型的输入，从而提升模型的准确性。图 5-4 展示了数据预处理模块：




图 5-4 数据预处理功能示意图

(4) 推荐引擎功能

用户注册并登录系统后，进入系统首页，在“为你推荐”模块中，混合推荐系统根

据用户行为历史向用户推送符合其兴趣的视频，而“排行榜”模块展示的是近期比较热门的电影。本系统推荐引擎模块采用的是第三章提出的混合策略推荐算法，该算法融合基于用户和基于物品的协同过滤推荐算法，解决了单一推荐方法中存在的冷启动、计算复杂度高和推荐创新性问题，给用户提供更精确的推荐结果。系统引擎功能是完成推荐功能的重要组成部分^[59]，它通过数据预处理技术收集用户的观看记录和评分，并将这些信息输入到混合推荐模型中，从而根据用户的兴趣爱好为他们选择最合适的影片。推荐引擎功能用示意图如下所示：




图 5-5 推荐引擎功能示意图

(5) 管理员系统功能

电影推荐系统提供了一个完备的管理员系统，它将用户信息管理、电影信息管理、电影评分、电影评论管理等功能集于一体，使管理员能够更加有效地管理电影信息。后台管理人员通过使用管理员系统可以方便快捷地管理后台，从而实现电影推荐系统的信息化管理：后台管理人员登录管理员系统，通过系统提供的管理员功能来维护整个电影推荐系统的正常运行。同时，后台管理人员还可以通过用户的反馈信息，对系统进行改良，从而提供更好的服务。管理员功能图如图 5-6 所示：




图 5-6 管理员功能示意图

5.1.3 非功能性需求分析

电影是人们日常生活中最喜欢的娱乐方式之一，然而电影种类繁多，如何挑选符合自己兴趣爱好的电影成了一个难题。当人们无法准确描述自己想要观看的电影时，传统的搜索引擎不能很好地满足人们的需求^[60]。为了满足用户需求，本文搭建了一个电影推荐系统，方便人们快捷精准地找到自己感兴趣的电影的同时，也提升了用户体验。

为了更好地服务用户，系统还需要满足以下需求：1 准确性需求，电影推荐系统必须具备准确性高的特性^[61]，以便为用户提供符合其兴趣爱好的电影，其中算法的选择尤为重要。2 当用户和电影数量急速增长时，系统必须能够稳定运行。这就要求在搭建数据库时，考虑用户信息数据、用户行为数据、电影数据、推荐数据的存储问题。3 易用性需求：电影推荐系统前端网页风格一致，大气美观；操作页面简洁明了，易于上手。4 安全性需求：系统需要保证用户的隐私安全^[62]，故而前后端进行交互时采用高安全性的加密通信协议。5 可扩展性：系统采用目前前端开发的主流框架，Django 框架。该框架易于使用和理解，且扩展性强，能方便地进行二次开发或者对当前版本进行更新迭代。

5.2 系统设计

5.2.1 系统架构设计

根据系统的功能性和非功能性需求，本文采用用户交互层、接口层、业务逻辑层和数据处理层四层架构对电影推荐系统进行设计，如图 5-7 所示。



图 5-7 系统架构示意图

(1) 用户交互层

用户可以通过用户交互层与系统进行直接交互，这一层通常是基于 Vue、Css3 等技术构建的 web 网页，它的主要功能是将电影信息以及个性化的推荐服务呈现给用户，以满足用户的需求。登录系统后，用户可以查看系统根据自身偏好和兴趣爱好推荐的电影列表，以及当下最受欢迎的电影。用户的行为数据将被收集，并被用于推荐模型的训练和更新。

(2) 接口层

接口层将前后端的不同层类有机连接起来，规定了统一的 API(应用程序编程接口)。该层使得前后端易于使用和管理，同时也方便系统的功能扩展。

(3) 业务层

业务逻辑层对用户交互层传递的信息进行逻辑处理，并与数据层进行连接。该层的核心是混合策略推荐模型，混合推荐模型利用用户行为数据来为用户推荐合乎其兴趣爱好的视频列表。

(4) 数据处理层

数据处理层的功能是对用户数据进行采集和存储。数据采集过程主要是通过前端埋点的方式对用户数据进行收集与整理；数据存储过程主要是使用 MySQL 数据库对用户和电影的相关信息存储。

5.2.2 系统推荐流程

本系统推荐的工作流程如下：




图 5-8 系统推荐流程图

当使用者进入系统时，如果该使用者是老用户，系统会利用用户的历史行为数据来为其推荐合乎其兴趣爱好的视频列表；如果该使用者是新用户，系统将会根据当下最热门的视频来为用户进行推荐。新用户产生的行为数据又被用于推荐模型的训练，从而来提升模型的推荐服务。

5.2.3 数据库设计

数据库对用户和电影的相关信息存储，为电影推荐系统的运行提供数据基础。本系统采用的数据库是关系型数据库 MySQL，主要针对用户信息数据、电影信息数据、用户评分数据、推荐结果数据这 4 种数据设计数据表。

用户表收集了用户的个人资料，包含用户名、密码、年龄、性别、职业等。

表 5-2 用户表

序号	字段名	字段类型	描述	主键
1	id	int	用户 ID	是
2	username	varchar	用户名	
3	password	varchar	密码	
4	email	varchar	邮箱	
5	age	int	年龄	
6	gender	int	性别	
7	createtime	varchar	注册时间	
8	Career	varchar	职业	

电影表收集了电影的所有信息，包括电影 ID、电影名称、电影类型等。

表 5-3 电影表

序号	字段名	字段类型	描述	主键
1	id	int	电影 ID	是
2	itemname	varchar	电影名称	
3	typeid	int	电影类型	是
4	imege	varchar	电影封面	
5	content	text	电影简介	
6	createtime	varchar	添加时间	

电影评分表收集了用户对电影的评价和反馈。

表 5-4 电影评分表

序号	字段名	字段类型	描述	主键
1	id	int	交互 ID	是
2	score	int	评分	
3	userid	int	用户 ID	是
4	itemid	int	电影 ID	是
5	createtime	varchar	添加时间	

混合推荐算法计算得到的推荐结果数据表如表 5-5 所示。

表 5-5 推荐结果表


序号	字段名	字段类型	描述	主键
1	id	int	用户 ID	是
2	items	varchar	推荐列表	

5.3 系统功能的实现

本系统使用豆瓣电影数据来评估个性化电影推荐系统的性能，以确保它能够满足用户的需求。本文将测试并分析用户注册与登录、电影排行榜、电影推荐、电影分类、电影详情、评分和评论等功能。

5.3.1 注册与登录


用户系统为所有用户提供使用功能，但是只有登录的用户才能享受个性化推荐服务。在首页点击注册后会跳转到注册页面，用户使用注册的账号和密码进入电影推荐系统。如果输入有误(如输入电话格式不正确)，系统会给出提示，要求重新填写。用户注册页面如图 5-9 所示：



The image shows a user registration form titled "用户注册" (User Registration). It contains five input fields: "用户名" (Username) with placeholder "请输入用户名", "电话" (Phone) with placeholder "请输入电话", "邮箱" (Email) with placeholder "请输入邮箱", "密码" (Password) with placeholder "请输入密码", and "确认密码" (Confirm Password) with placeholder "请输入确认密码". Below the fields is a blue "注册" (Register) button. At the bottom, there is a link "已有账号? 直接登录" (Already have an account? Log in directly).

图 5-9 用户注册示意图

用户登陆页面如图 5-10 所示。用户输入用户名和密码，系统验证成功后，用户方能进入系统首页，如图 5-11 所示。



The image shows a user login form titled "用户登录" (User Login). It contains two input fields: "用户名" (Username) with the value "白胡子258" and "密码" (Password) with masked characters "*****". Below the fields is a red "登录" (Login) button. At the bottom, there is a link "没有账号? 点击注册" (No account? Click to register).

图 5-10 用户登录示意图



图 5-11 电影推荐系统首页

5.3.2 管理员系统功能

管理员系统主要功能包括电影类型管理、电影评分管理、电影评论管理、电影收藏管理等，如图 5-12 所示：




图 5-12 管理员系统

管理员通过系统提供的管理员功能来维护整个电影推荐系统的正常运行。“前台用户管理”提供了删除和重置密码、锁定和解锁用户等功能，方便后台对系统中的用户信

息和状态进行管理。“电影类型管理”可以增加或删除前端网页中电影的类型标签并对电影进行归类。管理员可以通过“电影管理”方便地增加或删除库中的电影。“电影评分管理”用来收集用户对电影的评分。经过测试,后台管理人员通过使用管理员系统可以方便快捷地管理后台,从而实现电影推荐系统的信息化管理。

5.3.3 普通用户功能

用户进入系统后,电影推荐系统分三个模块为用户提供服务,分别是排行榜、为你推荐和最新电影。



图 5-13 排行榜板块

网站提供悬疑类、喜剧类、历史类和动作类电影的排行榜,根据用户对各类电影评分,降序排列并选出评分最靠前的电影为用户进行推荐。当用户有心仪的电影想要观看时,只需要在搜索框(排行榜的正上方)中输入相关电影信息,系统就会对目标电影进行检索,如图 5-14 所示。




图 5-14 搜索功能

“为你推荐板块”针对不同用户提供不同的推荐服务。当一个用户进入系统时，如果该用户是老用户，系统会利用用户的历史行为数据来为其推荐合乎其兴趣爱好的视频列表；如果该用户是新用户或者未注册用户，系统会按照评分从高的顺序对电影进行排序，并为用户推荐评分最高的 12 部电影。新用户产生的行为数据将被用于推荐模型的训练，从而来提升系统的推荐服务。




图 5-15 为你推荐板块

在“最新电影”板块点击“查看更多按钮”，我们能够看到电影的全部分类，包括

武侠、动作、爱情、科幻、动画、悬疑、惊悚等。当用户选择影片分类列表页面中的任何一个影片时，就会进入到该电影的详情页面，并查看到该影片的详细信息以及它们的最新动态。




图 5-16 全部电影板块

在用户的详情页面，系统分为三个模块为用户提供服务，分别是电影简介、相关推荐和电影评价模块。电影简介模块对故事背景及内容进行概括，在其上方对电影的主演、导演、电影类型等进行了介绍，此外，本模块还提供了“豆瓣电影”、“收藏电影”、“播放电影”三个功能，用户可根据自己的需求进行选择。相关推荐模块向用户推荐和当前电影风格类似的电影。在最下方的电影评价模块，用户对当前电影进行评分和评论，系统会收集用户评价数据来对推荐结果进行更新，以便能为用户提供更加优良的推荐服务。



图 5-17 电影详情页 1



图 5-18 电影详情 2

邀请了几位用户对本系统进行注册使用，使用过程中用户登录页面、电影首页、电影分类页面、电影详情页面以及用户个人页面均加载正常，页面之间的跳转十分流畅，系统推荐的电影也符合用户的需求，基本符合功能设计预期。

5.4 本章小结

本章基于第三章提出的混合推荐算法开发了一套个性化电影推荐系统，首先分析讨论了该系统的可行性和功能需求，接下来从系统总体架构和数据库的构建入手阐述系统的工作流程，最后对系统功能进行实现和测试。测试结果表明，本系统简约大方，运行稳定，跳转流畅，并且能为用户提供优良的个性化推荐服务，具有一定的实用价值。

第6章 总结与展望

由于科技的发展和电子商务的兴起,互联网上的个人信息总量呈指数级增加,人们面临着信息过载的挑战。为了有效地获取所需资讯,科学家们提出了多种建议,其中推荐系统是最受学术界关注且最有效的方案之一。推荐系统的优点在于,它能够根据用户兴趣爱好为其提供优质的个性化推荐服务。协同过滤算法是推荐场景中应用较多且性能较好的推荐算法。本文对传统协同过滤算法进行改良,使其能够为用户提供更加优良的个性化推荐服务,并使用改进后的推荐算法设计实现了个性化电影推荐系统。本文主要工作如下:

1.本文提出一种混合策略推荐算法。每种推荐算法都存在自己的优劣势。通过使用基于用户的协同过滤算法,我们可以根据用户的历史行为信息来预测评分,这种方法的精确度和新颖性较高,但是存在一些缺陷,例如数据稀疏和新用户冷启动;基于物品的协同过滤算法通过寻找和用户喜好商品相似的物品,来为用户提供推荐服务。该算法可解释性好,计算复杂度较低,而且能够在一定程度上解决新用户的冷启动问题。但是基于物品的协同过滤算法推荐的商品新颖性和多样性较低。为了有效结合两种算法的优势,本文对两种协同过滤算法进行加权融合,从而能够为用户提供更加优良的个性化推荐服务。在实验过程中,本文发现,使用余弦相似度来计算样品相似度存在一定缺陷,因而改为使用修正余弦相似度。实验证明,本文提出的混合推荐算法具有较好的推荐性能。

2.为了克服传统协同过滤推荐系统中的数据稀疏问题,本文提出了一个新的解决方法:首先使用 K-means++ 聚合技术,将用户分为多个簇,并在每一簇内重新建立用户-物品评分矩阵,以此来减少数据稀疏性。然后,本文使用更新后的矩阵来运行基于用户的协同过滤算法。在实现算法的过程中,本文发现热门商品会影响用户相似度的计算准确性,为此本文在计算用户相似度时加入了热门商品的惩罚因子,这样能够帮助目标用户更加准确地找到近邻用户。实验证明,本文提出的基于用户聚类和改进用户相似度的协同过滤算法在性能上优于传统协同过滤算法。

3.本章设计并实现了一套电影推荐系统,该系统基于混合推荐算法,旨在为客户带来个性化的电影推荐服务。为了达到这一目标,该系统采取了前后端分离的方式进行开发,前端应用了 Vue.js 架构,后端则应用了经典的 MVC 架构和 Python 的 Django 架构。系统根据使用对象的不同为用户提供普通用户功能或者管理员功能。普通用户功能包括排行榜推荐、个性化推荐、非个性化推荐、观看电影、电影评分和评论等。管理员系统主要功能包括前台用户管理、电影类型管理、电影评分管理、电影评论管理等。经测试,系统运行流畅,能够很好地为用户提供推荐服务。

本文提出的改进算法能够很好地解决数据稀疏、推荐物品创新性低、用户相似度计算准确度较差等问题，从而提升系统推荐性能。但是所做的研究还是不够深入，接下来将从以下几个方面继续完善本文的工作：

1.相较于单一的算法，本文提出的加权混合推荐算法的推荐效果要更好，但是该算法确定权值的过程需要耗费大量时间，而且计算过程中存在未知因素的干扰，可能会导致推荐失败。下一步，我们将探索如何能够高效准确地确定权值，从而为用户提供更加优质的推荐服务。

2.本文使用了 K-means++ 聚类方法，它可以有效避免传统 K-means 算法中存在的随机选取初始聚类中心而导致的聚类结果不精确的现象。但是同样需要经过大量实验来决定聚类数(k 值)，这样会耗费大量的时间，接下来我们将对 K-means++ 算法进行改进，使其能够自动标定 k 值。

3.本文在计算用户相似度时加入了热门商品惩罚因子，这样能够帮助目标用户更加准确地找到近邻用户，从而提升推荐性能。但是经过调研，我们发现时间因素对用户的兴趣也会产生影响，因此接下来我们将会现有的推荐算法基础上加入用户兴趣-时间影响因子。

4.本文搭建的电影推荐系统刚开放使用，目前用户和电影数量都不多，未来将在学校及社会进行推广，收集用户反馈信息并不断地完善功能，以满足人们的需求。

参考文献

- [1]朱冬亮, 文奕, 万子琛. 基于知识图谱的推荐系统研究综述[J]. 数据分析与知识发现, 2021, 5(12):1-13.
- [2]黄立威, 江碧涛, 吕守业, 刘艳博, 李德毅. 基于深度学习的推荐系统研究综述[J]. 计算机学报, 2018, 41(07):1619-1647.
- [3]李盼颖. 基于协同过滤的个性化推荐算法[D]. 河北建筑工程学院, 2022.
- [4]陈昌凤, 师文. 个性化新闻推荐算法的技术解读与价值探讨[J]. 中国编辑, 2018(10):9-14.
- [5]陈国青, 任明, 卫强, 郭迅华, 易成. 数智赋能:信息系统研究的新跃迁[J]. 管理世界, 2022, 38(01):180-196.
- [6]Scheibe M M, Imboden J B, Schmajuk G, et al. Efficiency gains for rheumatology consultation using a novel electronic referral system in a safety-net health setting[J]. Arthritis care & research, 2015, 67(8):1158-1163.
- [7]Anderson C. The long tail: Why the future of business is selling less of more[M]. Hachette UK, 2006:30-35.
- [8]Schafer J B, Konstan J, Riedl J. Recommender systems in e-commerce[C]//Proceedings of the 1st ACM conference on Electronic commerce. 1999:158-166.
- [9]Kant S, Mahara T. Merging user and item based collaborative filtering to alleviate data sparsity[J]. International Journal of System Assurance Engineering and Management, 2018, 9:173-179.
- [10]杨博, 赵鹏飞. 推荐算法综述[J]. 山西大学学报(自然科学版), 2011, 34(03):337-350.
- [11]Sarwar B, Karypis G, Konstan J, et al. Analysis of recommendation algorithms for e-commerce[C]//Proceedings of the 2nd ACM Conference on Electronic Commerce. 2000: 158-167.
- [12]Goyani M, Chaurasiya N. A review of movie recommendation system: Limitations, Survey and Challenges[J]. ELCVIA: electronic letters on computer vision and image analysis, 2020, 19(3):18-37.
- [13]Armstrong R. Wab Watcher: A Learning Apprentice for the World Wide Web[C]//The AAAI Spring Symposium on Information Gathering from Heterogeneous, Distributed Environment. 1995:345-357.
- [14]Jiang L, Cheng Y, Yang L, et al. A trust-based collaborative filtering algorithm for E-commerce recommendation system[J]. Journal of ambient intelligence and humanized

- computing, 2019, 10: 3023-3034..
- [15]Ma H, Yang H, Lyu M R, et al. Sorec: social recommendation using probabilistic matrix factorization[C].Proceedings of the 17th ACM conference on Information and knowledgemanagement. ACM, 2008: 931-940.
- [17]Bao Y, Fang H, Zhang J. Leveraging decomposed trust in probabilistic matrix factorization for effective recommendation[C].Proceedings of the 28th AAAI Conference on Artificial Intelligence (AAAI). 2014: 350-352.
- [18]Cheng H T, Koc L, Harmsen J, et al. Wide & deep learning for recommender systems[C]. Proceedings of the 1st workshop on deep learning for recommender systems. 2016: 7-10.
- [19]Manotumruksa J, Macdonald C, Ounis I. A contextual attention recurrent architecture for context-aware venue recommendation[C]. The 41st international ACM SIGIR conference on research & development in information retrieval. 2018: 555-564.
- [20]Rachamadugu S K, Dwaram J R, Patike K R. Recommender System based on Deep Neural Network and Long Short Term Memory[C]//2021 International Conference on Computing, Networking, Telecommunications & Engineering Sciences Applications (CoNTESA). IEEE, 2021: 50-55.
- [21]Gupta M, Thakkar A, Gupta V, et al. Movie recommender system using collaborative filtering[C]//2020 International Conference on Electronics and Sustainable Communication Systems (ICESC). IEEE, 2020: 415-420.
- [22]Melchiorre A B, Rekabsaz N, Parada-Cabaleiro E, et al. Investigating gender fairness of recommendation algorithms in the music domain[J]. Information Processing & Management, 2021, 58(5): 102666.
- [23]朱志慧, 田婧, 林捷. 大数据环境下基于用户位置的个性化音乐推荐系统设计[J]. 无线互联科技, 2019, 16(02):79-80.
- [24]Gai K, Zhu X, Li H, et al. Learning piece-wise linear models from large scale data for ad click prediction[J]. arXiv preprint arXiv:1704.05194, 2017.
- [25]Guo H, Tang R, Ye Y, et al. DeepFM: a factorization-machine based neural network for CTR prediction[J]. arXiv preprint arXiv:1703.04247, 2017.
- [26]Lian J, Zhou X, Zhang F, et al. xdeepfm: Combining explicit and implicit feature interactions for recommender systems[C]//Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 1754-1763.
- [27]黎楷文. 基于知识图谱与深度学习的个性化旅游推荐[D]. 海南大学,2022.
- [28]Zhang W, Wei W, Xu L, et al. Ai matrix: A deep learning benchmark for alibaba data

- centers[J]. arXiv preprint arXiv:1909.10562, 2019: 1674-1745.
- [29]姜雨霖, 冯相忠. 基于协同过滤和用户画像的流媒体推荐系统研究[J]. 电脑与信息技术, 2021, 29(05):37-41.
- [30]Javed U, Shaukat K, Hameed I A, et al. A review of content-based and context-based recommendation systems[J]. International Journal of Emerging Technologies in Learning (iJET), 2021, 16(3): 274-306.
- [31]陈勇. 基于协同过滤算法的旅游推荐系统的设计[J].价值工程,2022,41(30):160-162.
- [32]Koren Y, Rendle S, Bell R. Advances in collaborative filtering[J]. Recommender systems handbook, 2021: 91-142.
- [33]Kluver D, Ekstrand M D, Konstan J A. Rating-based collaborative filtering: algorithms and evaluation[J]. Social information access: Systems and technologies, 2018: 344-390.
- [34]王子茹, 宋尚文, 阎红灿. 协同过滤推荐算法的性能对比与分析[J]. 计算机仿真, 2022, 39(09):435-440
- [35]罗洁, 王力. 基于用户和项目的协同过滤算法的比较研究[J]. 智能计算机与应用, 2023, 13(01):195-197.
- [36]Ajaegbu C. An optimized item-based collaborative filtering algorithm[J]. Journal of ambient intelligence and humanized computing, 2021: 1-8.
- [37]Xue F, He X, Wang X, et al. Deep item-based collaborative filtering for top-n recommendation[J]. ACM Transactions on Information Systems (TOIS), 2019, 37(3): 1-25.
- [38]龚四相. 基于 Spark 的混合推荐系统分析与实现[D]. 长江大学,2020.
- [39]Tian Y, Zheng B, Wang Y, et al. College library personalized recommendation system based on hybrid recommendation algorithm[J]. Procedia CIRP, 2019, 83: 490-494.
- [40]Amatriain X, Jaimes* A, Oliver N, et al. Data mining methods for recommender systems[M]//Recommender systems handbook. Boston, MA: Springer US, 2010: 39-71.
- [41]Nilashi M. An overview of data mining techniques in recommender systems[J]. Journal of Soft Computing and Decision Support Systems, 2016, 3(6): 16-44.
- [42]朱本瑞. 基于 Spark 的离线与实时的电影推荐系统设计与实现[D]. 南京信息工程大学, 2022.
- [43]张泽文. 基于知识图谱的电影推荐系统的研究与实现[D]. 南昌大学, 2021.
- [44]Goyani M, Chaurasiya N. A review of movie recommendation system: Limitations, Survey and Challenges[J]. ELCVIA: electronic letters on computer vision and image analysis, 2020, 19(3): 18-37.
- [45]Ginart A A, Naumov M, Mudigere D, et al. Mixed dimension embeddings with

- application to memory-efficient recommendation systems[C]//2021 IEEE International Symposium on Information Theory (ISIT). IEEE, 2021: 2786-2791.
- [46]Talwar S, Dhir A, Scuotto V, et al. Barriers and paradoxical recommendation behaviour in online to offline (O2O) services. A convergent mixed-method study[J]. Journal of Business Research, 2021, 131: 25-39.
- [47]李启序. 基于协同过滤的个性化推荐系统的研究[D]. 安徽理工大学,2019.
- [48]吴猛华. 基于协同过滤的影视推荐系统设计与实现[D]. 华东师范大学,2022.
- [49]He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]//Proceedings of the 26th international conference on world wide web. 2017: 173-182.
- [50]Ortega F, Rojo D, Valdiviezo-Diaz P, et al. Hybrid collaborative filtering based on users rating behavior[J]. IEEE Access, 2018, 6: 69582-69591.
- [51]汪宇. 基于 k-means 用户聚类的混合协同过滤算法的研究[D]. 吉林大学,2016.
- [52]余方鑫. 基于协同过滤的混合推荐方法研究[D].广西大学,2022.
- [53]Li P, Han Y, Wen X, et al. Improvement and Research of Collaborative Filtering Algorithm Based on Penalty Factor[C]//Journal of Physics: Conference Series. IOP Publishing, 2022, 2209(1): 12026.
- [54]步东拯. 基于 Spark 的养殖信息推荐系统研究与应用[D]. 华北水利水电大学, 2022.
- [55]冯旭辉. 个性化信息推荐系统的应用与研究[D]. 太原科技大学, 2021.
- [56]Xu Z, Xu H, Yuan H, et al. Collaborative Filtering Recommendation Algorithm Based on Category and Penalty[C]//Proceedings of the International Conference on Compute and Data Analysis. 2017: 202-206.
- [57]吴猛华. 基于协同过滤的影视推荐系统设计与实现[D].华东师范大学,2022.
- [58]杨枝蕊. 基于用户协同过滤的短视频推荐优化方法研究[D].北京交通大学,2022.
- [59]张坤. 基于 Spark 机器学习的电影推荐系统的设计与实现[D]. 南京邮电大学,2022.
- [60]Subramaniaswamy V, Logesh R, Chandrashekhar M, et al. A personalised movie recommendation system based on collaborative filtering[J]. International Journal of High Performance Computing and Networking, 2017, 10(1-2): 54-63.
- [61]胡俊凯. 基于 Web 的个性化电影推荐系统设计与实现[D]. 广东工业大学,2022.
- [62]Furtado F, Singh A. Movie recommendation system using machine learning[J]. International journal of research in industrial engineering, 2020, 9(1): 84-98.